

**UNIVERSIDADE TECNOLÓGICA FEDERAL DO PARANÁ**

**CRISTIAN VEGGIAN MATIAS**

**DESENVOLVIMENTO DE UMA INTERFACE GRÁFICA PARA CLASSIFICAÇÃO  
DE PADRÕES DE SINAIS NEUROELÉTRICOS NÃO-INVASIVOS DE  
IMAGÉTICA MOTORA PARA INDIVÍDUOS COM LESÃO MEDULAR**

**APUCARANA**

**2024**

**CRISTIAN VEGGIAN MATIAS**

**DESENVOLVIMENTO DE UMA INTERFACE GRÁFICA PARA CLASSIFICAÇÃO  
DE PADRÕES DE SINAIS NEUROELÉTRICOS NÃO-INVASIVOS DE  
IMAGÉTICA MOTORA PARA INDIVÍDUOS COM LESÃO MEDULAR**

**Developing a graphical interface for pattern recognition on non-invasive  
neuroelectric signals of motor imagery for individuals with spinal chord  
injuries**

Trabalho de Conclusão de Curso de Graduação  
apresentado como requisito para obtenção  
do título de Bacharel em Engenharia de  
Computação do Curso de Bacharelado em  
Engenharia de Computação da Universidade  
Tecnológica Federal do Paraná.

Orientador: Prof. Dr. Daniel Prado de Campos

**APUCARANA**

**2024**



[4.0 Internacional](https://creativecommons.org/licenses/by/4.0/)

Esta licença permite compartilhamento, remixe, adaptação e criação a partir do trabalho, mesmo para fins comerciais, desde que sejam atribuídos créditos ao(s) autor(es). Conteúdos elaborados por terceiros, citados e referenciados nesta obra não são cobertos pela licença.

**CRISTIAN VEGGIAN MATIAS**

**DESENVOLVIMENTO DE UMA INTERFACE GRÁFICA PARA CLASSIFICAÇÃO  
DE PADRÕES DE SINAIS NEUROELÉTRICOS NÃO-INVASIVOS DE  
IMAGÉTICA MOTORA PARA INDIVÍDUOS COM LESÃO MEDULAR**

Trabalho de Conclusão de Curso de Graduação  
apresentado como requisito para obtenção  
do título de Bacharel em Engenharia de  
Computação do Curso de Bacharelado em  
Engenharia de Computação da Universidade  
Tecnológica Federal do Paraná.

Data de aprovação: 25/junho/2024

---

Prof. Dr. Rafael Gomes Mantovani  
Universidade Tecnológica Federal do Paraná

---

Me. Hygor Martins Pereira  
Universidade Tecnológica Federal do Paraná

---

Prof. Dr. Daniel Prado de Campos  
Universidade Tecnológica Federal do Paraná

**APUCARANA**

**2024**

Dedico esse trabalho aos meus pais e à minha  
vó, sem os quais eu não teria conseguido subir  
nos ombros dos gigantes para enxergar mais  
longe.

## **AGRADECIMENTOS**

Gostaria de agradecer inicialmente a Deus, pois vejo em tudo que me cerca Suas mãos, por toda a força que proporcionou em mim durante toda a minha vida.

Também agradeço à toda minha família, que sempre depositou confiança em mim e apoiou minhas escolhas, em especial aos meus pais, Alex e Solange, e à minha avó, Terezinha.

Agradeço aos meus amigos e suas famílias, por terem aguentado minha loucura, pelos momentos de descontração e pelas experiências e lições de vida que me proporcionaram durante nossa convivência.

Ofereço meus mais sinceros agradecimentos ao corpo docente da UTFPR, principalmente aos professores de Engenharia da Computação, em especial ao meu orientador, Prof. Dr. Daniel Prado de Campos, que além de me guiar nessa incrível e árdua tarefa, também aguentou um pouco da minha loucura.

Extendo por último meus agradecimentos a todas as outras pessoas que contribuíram direta ou indiretamente ao meu processo de formação, meus colegas de trabalho e professores do ensino fundamental e médio, especialmente aos professores Paulo Vaz e Elisângela pelo apoio descomunal em me fazer entrar na faculdade.

"Ainda assim", disse o Espantalho, "quero um cérebro em vez de um coração; porque um tolo não saberia o que fazer com um coração se tivesse um."

"Fico com o coração", respondeu o Homem de Lata, "porque cérebro não faz ninguém feliz, e a felicidade é a melhor coisa do mundo."

L. Frank Baum, em O Mágico de Oz.

## RESUMO

A cada ano, o número de indivíduos que sofrem com inabilidades motoras provenientes de lesões medulares ou outros distúrbios neurológicos aumenta. Entre as técnicas de tecnologia assistivas utilizáveis nesses indivíduos, o uso de interfaces cérebro-máquina que processam biosinais de eletroencefalografia tem se tornado cada vez mais comum. Esses sinais carregam informações importantes dentro desse contexto como recepção de estímulos externos e imagética motora, descrita como a resposta do cérebro à imaginação ou intenção do movimento sendo executado. Neste trabalho foi desenvolvida uma aplicação para realizar a coleta e armazenamento de sinais de eletroencefalografia de imagética motora, para que os dados pudessem ser utilizados posteriormente no treinamento de modelos de aprendizado de máquina e aprendizado profundo. Também foram adicionados métodos de extração de características e classificação de padrões, de forma a permitir os testes com *datasets* diferentes, tanto de públicos como das coletas realizadas pelo software. Foram implementados os métodos de Análise de Discriminante Linear, K-vizinhos próximos, Perceptron Multicamadas e Máquina de Vetores de Suporte. Os testes realizados com *datasets* da internet geraram resultados aceitáveis, com acurácias de até 93% dentre os *pipelines* aplicados a alguns indivíduos do *dataset*.

**Palavras-chave:** aprendizado de máquina; eletroencefalografia; inteligência artificial; interfaces cérebro-computador; processamento de sinais.

## ABSTRACT

Each year, the number of individuals suffering from motor disabilities due to spinal cord injuries or other neurological disorders increases. Among the assistive technology techniques applicable to these individuals, the use of brain-machine interfaces that process biosignals from electroencephalography (EEG) has become increasingly common. These signals carry important information within this context, such as movement intention, reception of external stimuli and motor imagery, described as the brain's response to imagining or intending a specific movement. In this work, an application was developed to collect and store motor imagery EEG signals, which could later be used for training machine learning or deep learning models. Feature extraction and pattern classification methods were also incorporated to allow testing with different datasets, both from public and those collected by the software. The implemented methods include Linear Discriminant Analysis, k-Nearest Neighbors, Multilayer Perceptron, and Support Vector Machines. Tests conducted with internet datasets yielded acceptable results, achieving accuracies of up to 93% across the pipelines applied to some individuals in the dataset.

**Keywords:** machine learning; electroencephalography; artificial intelligence; brain-computer interface; signal processing.



## LISTA DE FIGURAS

Figura 1 – Medula espinal. . . . .	20
Figura 2 – Divisão do encéfalo. . . . .	21
Figura 3 – Lobos do cérebro. . . . .	21
Figura 4 – Representação de um neurônio. . . . .	23
Figura 5 – Exemplos de Sinais no domínio do tempo. . . . .	24
Figura 6 – Sinal, decomposição e frequências. . . . .	25
Figura 7 – Meninges e espaços do cérebro. . . . .	27
Figura 8 – Sistemas de posicionamento de eletrodos. . . . .	27
Figura 9 – Eletrodo seco de ouro para EEG. . . . .	28
Figura 10 – Representação de um <i>headplot</i> de um CSP . . . . .	30
Figura 11 – Representação do processo de uma interface cérebro-máquina. . . . .	31
Figura 12 – Exemplo gráfico de uma SVM linear. . . . .	32
Figura 13 – Exemplo gráfico de uma LDA. . . . .	33
Figura 14 – Exemplo gráfico de um kNN. . . . .	34
Figura 15 – Modelo do Neurônio de McCulloch-Pitts. . . . .	35
Figura 16 – Diferença entre <i>pipelines</i> de processamento. . . . .	35
Figura 17 – Fluxograma de desenvolvimento do trabalho . . . . .	36
Figura 18 – Equipamentos utilizados na coleta de dados. . . . .	40
Figura 19 – Imagens do sistema de coleta. . . . .	41
Figura 20 – Erro ao inserir parâmetro de CSP. . . . .	43
Figura 21 – Interface gráfica de teste para inserção de parâmetros de CSP. . . . .	43
Figura 22 – Bandas de Frequência com melhores acurácias em laranja. . . . .	44
Figura 23 – Acurácias obtidas a partir dos experimentos realizados com janelas de tempo. . . . .	45
Figura 24 – Matrizes de confusão de cada algoritmo. . . . .	46
Figura 25 – Matrizes de confusão dos melhores algoritmos para cada indivíduo. . . . .	47
Figura 26 – Arquivo de coleta com eletrodos flutuantes . . . . .	48
Figura 27 – Tela principal do aplicativo. . . . .	49
Figura 28 – Tela de criação de usuário. . . . .	50

**Figura 29 – Tela de configuração de padrão comum espacial, do inglês *common spatial pattern* (CSP). . . . . 51**

## LISTA DE TABELAS

<b>Tabela 1 – Bandas de frequências de ondas do cérebro. . . . .</b>	<b>28</b>
<b>Tabela 2 – Descrição das tarefas utilizadas em cada sessão. . . . .</b>	<b>37</b>
<b>Tabela 3 – Hiperparâmetros <i>default</i> do método CSP. . . . .</b>	<b>37</b>
<b>Tabela 4 – Hiperparâmetros <i>default</i> dos métodos de classificação. . . . .</b>	<b>38</b>
<b>Tabela 5 – Informações presentes no banco de dados JSON. . . . .</b>	<b>40</b>
<b>Tabela 6 – Comparação de Acurácia dos métodos de ML . . . . .</b>	<b>44</b>
<b>Tabela 7 – Acurácia média e desvio padrão dos diferentes métodos de classificação. . . . .</b>	<b>46</b>
<b>Tabela 8 – Scores dos modelos selecionados. . . . .</b>	<b>48</b>

## LISTA DE ABREVIATURAS E SIGLAS

### Siglas

ANC	cancelamento de ruído adaptativo, do inglês <i>adaptive noise canceling</i>
ANN	redes neurais artificiais, do inglês <i>artificial neural network</i>
AR	auto regressão
AVC	acidentes vasculares cerebrais
BCI	interface cérebro máquina, do inglês <i>brain-computer interface</i>
CNN	rede neural convolucional, do inglês <i>convolutional neural network</i>
CSP	padrão comum espacial, do inglês <i>common spatial pattern</i>
CSSP	padrão comum espaço-espectral, do inglês <i>common spatial-spectral pattern</i>
DFT	transformada discreta de Fourier, do inglês <i>discrete Fourier transform</i>
DL	aprendizado profundo, do inglês <i>deep learning</i>
DNN	rede neural profunda, do inglês <i>deep neural network</i>
ECG	eletrocardiografia
EEG	eletroencefalografia
EMG	eletromiografia
FD	dimensão fractal, do inglês <i>fractal dimension</i>
FFT	transformada rápida de Fourier, do inglês <i>fast Fourier transform</i>
FT	transformada de Fourier, do inglês <i>Fourier transform</i>
GUI	interface gráfica de usuário, do inglês <i>graphical user interface</i>
HMM	modelo oculto de Markov, do inglês <i>hidden Markov model</i>
IA	inteligência artificial
ICA	análise de componente independente, do inglês <i>independent component analysis</i>

IDFT	transformada inversa discreta de Fourier, do inglês <i>inverse discrete Fourier transform</i>
IFT	transformada inversa de Fourier, do inglês <i>inverse Fourier transform</i>
IM	imagética motora
k-NN	'k' Vizinhos próximos, do inglês ' <i>k</i> ' <i>nearest neighbours</i>
LCD	decomposição de características em escala local, do inglês <i>local characteristic-scale decomposition</i>
LDA	análise de discriminante linear, do inglês <i>linear discriminant analysis</i>
MD	distância de Mahalanobis, do inglês <i>Mahalanobis distance</i>
MEG	magnetoencefalografia
ML	aprendizado de máquina, do inglês <i>machine learning</i>
MLP	Perceptron multi camadas, do inglês <i>multi-layer Perceptron</i>
MP	busca correlata, do inglês <i>matching pursuit</i>
NBC	classificador inocente de Bayes, do inglês <i>naive Bayes classifier</i>
OMS	Organização Mundial de Saúde
PET	tomografia por emissão de pósitrons, do inglês <i>positron emission tomography</i>
RM	ressonância magnética
RNN	rede neural recorrente, do inglês <i>recurrent neural network</i>
SNC	sistema nervoso central
SNP	sistema nervoso periférico
SS-CSP	padrão comum esparso espaço-espectral, do inglês <i>common sparse spatial-spectral pattern</i>
SVM	máquina de vetores de suporte, do inglês <i>support vector machine</i>
TDAH	transtorno de déficit de atenção e hiperatividade
TL	transferência de aprendizado, do inglês <i>transfer learning</i>
TW	transformada <i>Wavelet</i>

## SUMÁRIO

<b>1</b>	<b>INTRODUÇÃO</b>	<b>14</b>
<b>1.1</b>	<b>Contexto</b>	<b>14</b>
<b>1.2</b>	<b>Justificativa</b>	<b>16</b>
<b>1.3</b>	<b>Objetivos</b>	<b>16</b>
1.3.1	Objetivo geral	16
1.3.2	Objetivos específicos	17
<b>1.4</b>	<b>Estrutura do trabalho</b>	<b>17</b>
<b>2</b>	<b>REFERENCIAL TEÓRICO</b>	<b>19</b>
<b>2.1</b>	<b>Sistema Nervoso</b>	<b>19</b>
2.1.1	Anatomia e Fisiologia	19
2.1.2	Citologia do Sistema Nervoso	22
<b>2.2</b>	<b>Biossinais</b>	<b>24</b>
2.2.1	Sinais	24
2.2.2	Biossinais do Corpo Humano	26
2.2.3	Pré-processamento de Biossinais de Eletroencefalografia	29
<b>2.3</b>	<b>Interface cérebro-máquina</b>	<b>30</b>
<b>2.4</b>	<b>Aprendizado de Máquina</b>	<b>31</b>
<b>3</b>	<b>MATERIAIS E MÉTODOS</b>	<b>36</b>
<b>3.1</b>	<b>Classificação</b>	<b>36</b>
<b>3.2</b>	<b>Coleta de Dados</b>	<b>39</b>
<b>3.3</b>	<b>Interface</b>	<b>41</b>
<b>4</b>	<b>RESULTADOS</b>	<b>44</b>
<b>4.1</b>	<b>Classificação</b>	<b>44</b>
<b>4.2</b>	<b>Coleta de Dados</b>	<b>48</b>
<b>4.3</b>	<b>Interface</b>	<b>49</b>
<b>5</b>	<b>CONCLUSÕES</b>	<b>52</b>
<b>5.1</b>	<b>Discussão geral</b>	<b>52</b>
<b>5.2</b>	<b>Pesquisas e trabalhos futuros</b>	<b>52</b>
<b>5.3</b>	<b>Considerações finais</b>	<b>53</b>

**REFERÊNCIAS . . . . . 54**

# 1 INTRODUÇÃO

## 1.1 Contexto

Doenças não-comunicáveis são doenças não transmissíveis, adquiridas devido a condições genéticas, do estilo de vida ou do ambiente, como câncer, diabetes e bronquite. Segundo a Organização Mundial de Saúde (OMS), 75% das mortes no Brasil são causadas por doenças não-comunicáveis (World Health Organization, 2019). Dessas mortes, estima-se que em 2019, até 12% tenham sido causadas por lesões provenientes de acidentes de estrada, violência interpessoal ou autoprovocada<sup>1</sup> (World Health Organization, 2019). Os casos supracitados que não resultam em morte podem deixar sequelas severas, como incapacidades motoras causadas por traumas ou lesões medulares. Segundo a OMS, em 2021 aproximadamente 15,4 milhões de pessoas possuíam lesões medulares, decorrentes principalmente de acidentes de carro, quedas ou violência (World Health Organization, 2024). No entanto, o número de lesões medulares causadas por tumores ou doenças degenerativas tem aumentado significativamente com o envelhecimento da população (World Health Organization, 2024). Além de lesões medulares, outras causas de perda de movimento incluem acidentes vasculares cerebrais (AVC) e doença de Parkinson (ZHUANG *et al.*, 2020).

O uso de interface cérebro máquina, do inglês *brain-computer interface* (BCI) é uma das várias técnicas de reabilitação para indivíduos com deficiências motoras (MCFARLAND JANIS DALY; PARVAZ, 2017). Uma BCI permite a recepção de sinais biológicos, que são processados e utilizados para controlar dispositivos atuadores (como próteses ou órteses<sup>2</sup>) a fim de suprir ou substituir limitações de mobilidade ou cognição de pessoas afetadas por essas deficiências.

Dentre os sinais biológicos que podem ser utilizados para acionar os dispositivos, os mais utilizados atualmente são a eletromiografia (EMG), que captura e registra os potenciais de ação das células musculares, eletrocardiografia (ECG), que registra a atividade elétrica do coração e eletroencefalografia (EEG), que são sinais elétricos disparados pelo cérebro humano, decorrentes das reações eletroquímicas da ativação dos neurônios durante a percepção de eventos ou de estímulos enviados e recebidos pelo sistema nervoso. Os sinais de EEG também podem ser amplamente utilizados para diagnóstico e tratamento de distúrbios neurológicos, como epilepsia (MILNE-IVES *et al.*, 2023) e lesões medulares (JÚNIOR *et al.*, 2022). Referente ao auxílio no tratamento de lesões medulares, uma das técnicas mais comumente utilizadas consiste na classificação de imagética motora (IM), que é a resposta da parte do cérebro refe-

<sup>1</sup> Violência interpessoal refere-se a agressão física provocada por um indivíduo sobre outro, enquanto violência autoprovocada trata-se da agressão sobre si mesmo, referente automutilação ou tentativas de suicídio.

<sup>2</sup> Próteses são peças que substituem um membro de forma integral, geralmente utilizadas em membros perdidos em acidentes ou amputados, enquanto órteses são peças que auxiliam o funcionamento de um membro que porventura tenha perdido total ou parcialmente a sua função.



rente ao córtex motor quando o usuário imagina ou tenta realizar o movimento (SHARMA; KIM; GUPTA, 2022).

Os sinais de EEG passam por uma sequência de processos para serem utilizados de forma eficiente. Inicialmente, ocorre a etapa de pré-processamento para a diminuição da interferência de ruídos e a remoção de artefatos<sup>3</sup>. Em seguida passam por um extrator de características, onde são extraídos valores que podem ser levados a um modelo de classificação de padrões. Os modelos de classificação visam aprender a separar os sinais de acordo com classes ou eventos pré-estabelecidos, utilizando algoritmos de inteligência artificial (IA). No entanto esse processo de classificação apresenta desafios:

1. Coleta de Dados: Existem diversos *datasets* públicos de variadas tarefas de imagética motora<sup>4</sup>. No entanto, cada indivíduo realiza a intenção e imaginação de formas diferentes, além de necessitar treinar diferentes tarefas de imagética motora. Dessa forma, é necessário realizar diversas coletas de cada indivíduo. Ao realizar diretamente as coletas em um *script* de classificação, pode ser que ocorra a perda de dados. Como cada coleta requer uma grande preparação e costuma ser exaustiva para o indivíduo que está sendo alvo da captura de dados, a perda das informações obtidas a cada sessão impossibilita a criação de modelos customizados para cada indivíduo. Também dessa forma, é possível utilizar os dados coletados em outros modelos de classificação, como algoritmos de aprendizado profundo, do inglês *deep learning* (DL), que requerem grandes quantidades de dados.
2. Combinação de métodos e hiperparâmetros: Cada um dos variados métodos de aprendizado de máquina, do inglês *machine learning* (ML) possui diversificados hiperparâmetros, de acordo com sua formulação. Cada combinação de métodos extração de características, métodos de classificação de padrões e dos respectivos hiperparâmetros gera diferentes resultados, de acordo com o indivíduo e as condições de coleta. Como os dados são perdidos após a coleta, testar combinações diferentes com os mesmos dados torna-se impossível.
3. Processamento em tempo real: O principal objetivo da classificação de dados de biosinais aplicado à tecnologia de BCI é a ativação de dispositivos atuadores para reestabelecer funções. Porém o *delay* entre a ocorrência da imagética motora e o resultado da classificação não pode ser superior a 300 ms, de acordo com Englehart e Hudgins (2003), para que não seja perceptível pelo indivíduo.

<sup>3</sup> Artefatos são ruídos encontrados nos sinais coletados, devido a movimentos musculares involuntários como piscar de olhos e bater do coração (MUMTAZ; RASHEED; IRFAN, 2021).

<sup>4</sup> Alguns exemplos estão disponíveis em: <<https://github.com/meagmohit/EEG-Datasets>>. Acesso em 03 de janeiro de 2024

## 1.2 Justificativa

A realização deste trabalho visa abordar dois dos três problemas mencionados acima. Inicialmente, busca-se desenvolver uma interface gráfica onde podem ser realizadas a coleta e classificação dos dados sem necessidade de escrever nenhuma linha de código, possibilitando que pessoas que não sabem programar tenham acesso a essa tecnologia. Por consequência, busca-se evitar a perda dos dados coletados através do armazenamento em arquivos das coletas realizadas, para que possam ser utilizados posteriormente para treinamento de modelos de aprendizado profundo. Após isso, será possível testar diferentes métodos de extração e classificação, bem como seus respectivos hiperparâmetros, de forma a determinar qual melhor abordagem para aquele determinado indivíduo.

O trabalho abrange áreas de conhecimento referidas nas disciplinas de Processamento Digital de Sinais, Sistemas Inteligentes 1 e 2, Engenharia de Software e Instrumentação Eletrônica, bem como áreas externas da parte da saúde, tais quais neurologia, fisiologia e anatomia.

A pesquisa empreendida visa aprofundar a compreensão e análise dos variados procedimentos aplicáveis na classificação de biossinais de EEG voltados para a IM, permitindo validar diversas combinações de técnicas de pré-processamento, modelos e hiperparâmetros, tanto em cenários teóricos quanto práticos.

O estudo propôs uma interface gráfica para viabilizar a criação de pipelines eficientes para processamento de dados de IM com objetivo de facilitar a realização de testes sem necessidade de alterar extensas linhas de *scripts* de código, permitindo que o usuário modifique os hiperparâmetros do *pipeline* preenchendo um formulário com as opções disponíveis.

Os resultados encontrados através da ferramenta desenvolvida por esse trabalho podem ser utilizados como forma de validação de modelos para serem aplicados posteriormente em situações de reabilitação de indivíduos com imparidades motoras decorrentes de condições adversas do sistema nervoso, tais quais lesões medulares.

## 1.3 Objetivos

### 1.3.1 Objetivo geral

Desenvolver um modelo de classificação de padrões de sinais de EEG integrado a uma interface gráfica para coleta e processamento de dados de IM, através da criação de *pipelines* de processamento de dados usando técnicas escolhidas.

### 1.3.2 Objetivos específicos

1. Implementar métodos de pré-processamento de sinais de EEG, para remoção de artefatos e filtragem;
2. Implementar métodos de extração de características de sinais de eletroencefalografia filtrados;
3. Implementar métodos de classificação de eletroencefalografia <sup>5</sup>;
4. Permitir que sejam escolhidos quais métodos de pré-processamento, extração de características e classificação serão utilizados em sua execução do aplicativo;
5. Permitir que sejam criados perfis de coleta para separar os dados coletados de cada indivíduo;
6. Permitir que os perfis sejam exportados/importados, para que possam ser transferidos entre aplicações através de arquivos;
7. Possibilitar o armazenamento de dados dos voluntários, a fim de salvar os dados coletados para que sejam usados futuramente, como no treinamento de redes de aprendizado profundo e aplicação de técnicas de transferência de aprendizado, do inglês *transfer learning* (TL).

## 1.4 Estrutura do trabalho

Este trabalho adota a seguinte estrutura organizacional:

- O capítulo 2 contextualiza o leitor sobre o processamento de biossinais de eletroencefalografia, suas aplicações e conceitos necessários ao entendimento do trabalho. Também nesse capítulo são fundamentados os conceitos de aprendizado de máquina, descrevendo os principais modelos usados no campo de processamento de biossinais;
- No capítulo 3, serão apresentados detalhes sobre a metodologia adotada, juntamente com uma descrição dos materiais empregados no desenvolvimento deste trabalho. Esta seção oferecerá uma visão abrangente dos procedimentos e recursos utilizados para conduzir a pesquisa, fornecendo insights valiosos sobre a abordagem metodológica adotada;
- O capítulo 4 mostra os resultados obtidos utilizando imagens da interface gráfica desenvolvida e gráficos para mostrar as métricas obtidas nos testes realizados;

<sup>5</sup> Classificação online é aquela que classifica os sinais em tempo próximo ao real, enquanto as amostras estão sendo coletadas. A classificação offline usa um conjunto de dados fechado para classificar os dados.

- Por fim, no capítulo 5 são resumidos os principais resultados alcançados, destacando sua relevância e contribuição para o campo de estudo. Além disso, são ressaltadas as limitações encontradas durante o estudo e sugeridas direções para pesquisas futuras.

## 2 REFERENCIAL TEÓRICO

### 2.1 Sistema Nervoso


O sistema nervoso, uma rede intrincada de comunicação do organismo humano, é constituído pelo cérebro, medula espinhal e um extenso conjunto de nervos. Sua função abrange a coordenação de atividades voluntárias e involuntárias, assim como o processamento e a interpretação de informações sensoriais. Além disso, desempenha um papel crucial no controle de diversas funções vitais, incluindo o movimento, o pensamento e a respiração.

#### 2.1.1 Anatomia e Fisiologia

O sistema nervoso é anatomicamente separado em duas partes: sistema nervoso periférico (SNP) e sistema nervoso central (SNC). O SNP é composto pelos nervos cranianos, nervos espinhais e gânglios nervosos e é responsável por interligar os membros do corpo ao SNC. Já o SNC é composto pela medula espinhal (protegida pela coluna vertebral) e pelo encéfalo (protegido pelo crânio) (TORTORA; DERRICKSON, 2014).

A medula espinhal, representada na Figura 1, é situada no interior do canal vertebral e encontra-se protegida pela totalidade deste, bem como pelo líquido cefalorraquidiano e pelas membranas meníngeas que compõem o sistema nervoso central (dura-máter, aracnóide-máter e pia-máter). Anatomicamente, é constituída por 31 pares de nervos, distribuídos em 8 pares cervicais, 12 pares torácicos, 5 pares lombares, 5 pares sacrais e um par coccígeo. No âmbito funcional do sistema nervoso, sua principal atribuição consiste na transmissão de informações entre o encéfalo e estruturas periféricas como pele, músculos e articulações (BEAR; CONNORS; PARADISO, 2015).


Pode-se citar como partes constituintes da medula espinhal a substância cinzenta na qual o processo inicial de informações sensoriais e motoras ocorre, cujo corte transversal possui o formato de borboleta. Além desta, também pode-se citar a substância branca, uma camada de fibras nervosas que reveste a substância cinzenta e atua como principal transmissor de sinais elétricos entre o cérebro e o resto do corpo (TORTORA; DERRICKSON, 2014).

**Figura 1 – Medula espinal.**

**Fonte: Adaptado de Tortora e Derrickson (2014).**

O encéfalo por sua vez pode ser dividido em três outras estruturas, sendo elas o tronco encefálico, o cérebro e o cerebelo, como mostrado na Figura 2. O tronco encefálico é formado por três estruturas, chamadas de bulbo, ponte e mesencéfalo. Essas estruturas regulam aspectos do organismo como batimentos cardíacos, respiração, piscar dos olhos, tosse, espirros e soluços. O cerebelo se conecta ao tronco encefálico por três estruturas de ligação chamadas pedúnculos e é responsável pelos movimentos relacionados ao equilíbrio e à coordenação motora (TORTORA; DERRICKSON, 2014).


**Figura 2 – Divisão do encéfalo.**



**Fonte: Adaptado da Internet <sup>1</sup>.**

O cérebro, também conhecido como telencéfalo, é a maior parte do encéfalo, sendo responsável pelos pensamentos, memória, julgamento, percepção, linguagem, sentimentos e movimentos voluntários. É anatomicamente dividido em regiões chamadas lobos, denominadas de acordo com os ossos que recobrem cada área (TORTORA; DERRICKSON, 2014). As regiões podem ser vistas na Figura 3.

**Figura 3 – Lobos do cérebro.**



**Fonte: Adaptado de Bear, Connors e Paradiso (2015).**

<sup>1</sup> Disponível em: <<https://quizlet.com/gb/609174756/parts-of-the-brain-flash-cards/>>. Acesso em 24 de maio de 2024.

### 2.1.2 Citologia do Sistema Nervoso


O sistema nervoso é basicamente composto de dois tipos de células diferentes, os neurônios e as glias. Os neurônios são estruturas formadas por um conjunto de pequenas estruturas celulares (organelas) chamado soma, uma membrana neuronal, um citoesqueleto, axônios e dendritos. Cada uma dessas estruturas do neurônio desempenha funções importantes dentro da célula. O soma possui as organelas comuns às outras células do corpo humano, como o núcleo, material genético, retículo endoplasmático rugoso, retículo endoplasmático liso, aparelho de Golgi e a mitocôndria, conforme mostrado na Figura 4 (BEAR; CONNORS; PARADISO, 2015).

A membrana neuronal realiza a regulação das substâncias presentes nos fluídos que banham os neurônios e delimita o citoplasma interno dessas células. Essa membrana é flexível e mantém seu formato arredondado devido ao citoesqueleto, um sistema de suporte que combina microtúbulos, neurofilamentos e microfilamentos (BEAR; CONNORS; PARADISO, 2015).

Diferenciando-se das estruturas anteriormente delineadas, os axônios representam componentes distintivos dos neurônios, incumbidos da transmissão de informações entre unidades nervosas por meio de conexões denominadas sinapses. Estas últimas convertem estímulos químicos de uma célula em sinais elétricos, viabilizando a transmissão de dados para outro neurônio, onde o sinal elétrico é então reconvertido em um sinal químico. Os sinais são recebidos novamente através dos dendritos, que atuam como antenas receptoras dos sinais enviados pelos axônios (BEAR; CONNORS; PARADISO, 2015).



**Figura 4 – Representação de um neurônio.**



**Fonte: Adaptado de Tortora e Derrickson (2014).**

Os neurônios podem ser classificados de acordo com a sua expressão gênica ou com sua estrutura, baseado no número de neuritos (axônios e dendritos), no formato dos dendritos, no comprimento dos axônios e nas conexões da célula (TORTORA; DERRICKSON, 2014).


Nos espaços livres entre os neurônios, estão as glias, conjuntos de células que desempenham funções de suporte no sistema nervoso. Pode-se citar os astrócitos, que regulam os neurotransmissores gerados no processo de troca de informação da sinapse e os oligodendrócitos, que atuam como formadores da bainha de mielina que protege os axônios (TORTORA; DERRICKSON, 2014).

## 2.2 Biossinais


### 2.2.1 Sinais

Os sinais são representações organizadas de dados que capturam informações variadas de máquinas, equipamentos, sensores, organismos vivos, e outros elementos (NAJARIAN; SPLINTER, 2012), os quais são geralmente registrados em função do tempo. Tais sinais podem ser classificados como analógicos ou digitais no que concerne à variável temporal, e como discretos ou contínuos no que se refere à amplitude. Nos sinais analógicos, o domínio temporal é contínuo (conforme ilustrado nas Figuras 5.a e 5.b), significando que para cada valor  $t \in \mathbb{R}$  de tempo, existe um valor correspondente para o sinal. Por outro lado, nos sinais digitais, os instantes temporais são discretos e ocorrem em múltiplos de uma taxa de amostragem específica (representados nas figuras 5.c e 5.d) (NALON, 2009).


**Figura 5 – Exemplos de Sinais no domínio do tempo.**




**(a) Sinal Analógico e Contínuo**



**(b) Sinal Analógico e Discreto**



**(c) Sinal Digital e Contínuo**



**(d) Sinal Digital e Discreto**

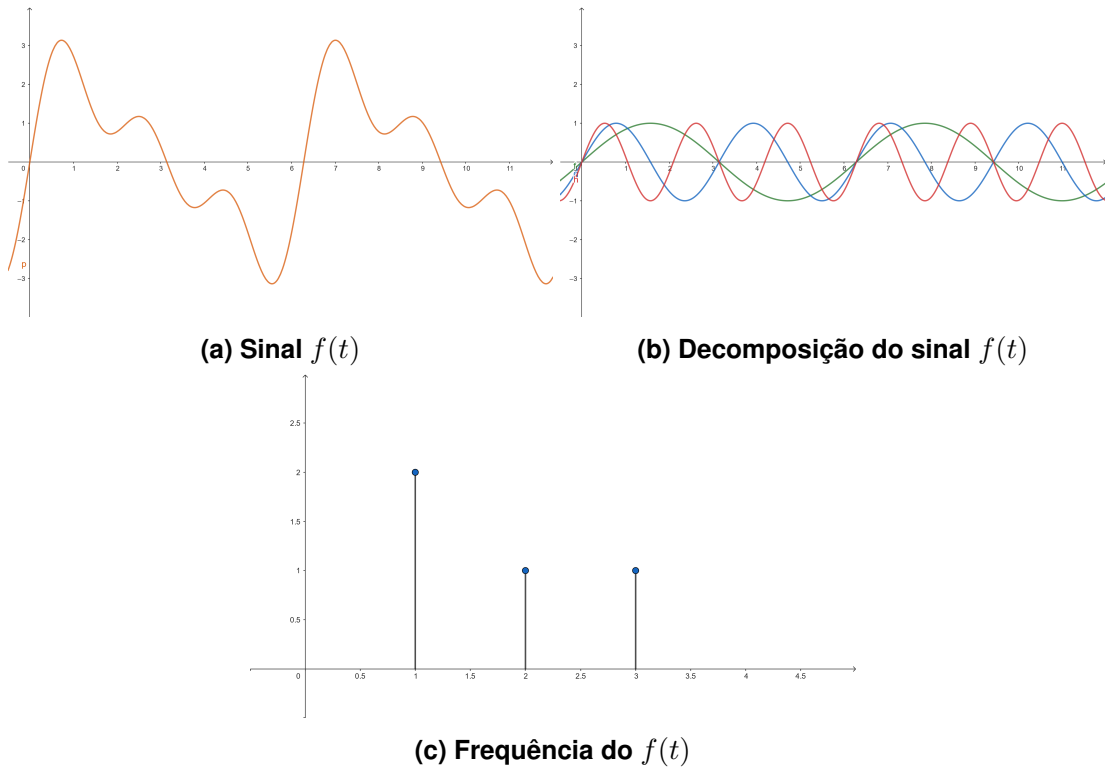
**Fonte: Autoria própria (2024).**

Em relação aos sinais discretos, os valores de amplitude que o sinal pode assumir pertencem a um conjunto finito e discreto. Nas figuras 5.b e 5.d, por exemplo, os sinais podem apenas atingir os valores de amplitude 1 e  $-1$ , enquanto nos sinais analógicos, todos os valores de amplitude  $y(t) \in \mathbb{R}$  podem ser alcançados, como evidenciado nas figuras 5.a e 5.c (OPPENHEIM; SCHAFER, 2013).

Além disso, os sinais podem ser transformados para outros domínios sem perder sua capacidade representativa dos fenômenos medidos. No campo do processamento de sinais a

representação do sinal no domínio da frequência é constantemente necessária. Este domínio quantifica a ocorrência de determinados eventos ou amplitudes no sinal e pode ser encontrado por meio da transformada de Fourier, do inglês *Fourier transform* (FT) (NAJARIAN; SPLINTER, 2012).

**Figura 6 – Sinal, decomposição e frequências.**



**Fonte: Autoria própria (2024).**

A Figura 6.a ilustra um sinal  $f(t)$  analógico e contínuo, que pode ser decomposto em três frequências fundamentais, (Figura 6.b), através da Equação 1.

$$f(t) = 2 \sin t + \sin 2t + \sin 3t \quad (1)$$

Já a Figura 6.c mostra o gráfico no domínio da frequência do sinal  $f(t)$ , que pode ser observado empiricamente através da equação 1, na qual os coeficientes multiplicativos dos termos senoidais representam as amplitudes, e os valores de frequência que multiplicam a variável  $t$  representam as frequências. A formulação para realizar a FT de uma função  $g(t)$  genérica é descrita pela Equação 2 (OPPENHEIM; SCHAFER, 2013).

$$G(f) = \int_{-\infty}^{+\infty} g(t) e^{-j2\pi ft} dt \quad (2)$$

Como a FT mantém as propriedades do sinal, ela permite que o sinal seja transformado para o domínio do tempo novamente, através de uma transformada inversa de Fourier, do inglês *inverse Fourier transform* (IFT), descrita na Equação 3.

$$g(t) = \int_{-\infty}^{+\infty} G(f)e^{j2\pi ft}df \quad (3)$$

Da mesma forma, também é possível realizar a transformação do domínio do tempo discreto para o domínio da frequência discreta, através de uma transformada discreta de Fourier, do inglês *discrete Fourier transform* (DFT), conforme mostra a Equação 4.

$$G(k) = \sum_{n=0}^{N-1} g(n)e^{-j\frac{2\pi knT}{N}}, k = 0, \dots, N-1 \quad (4)$$

Analogamente à IFT, também é possível realizar uma transformada inversa discreta de Fourier, do inglês *inverse discrete Fourier transform* (IDFT), também conhecida como síntese, para retornar uma função de frequência discreta para o tempo discreto. Essa fórmula está elucidada na Equação 5.

$$g(n) = \frac{1}{N} \sum_{k=0}^{N-1} G(k)e^{j\frac{2\pi knT}{N}}, n = 0, \dots, N-1 \quad (5)$$

## 2.2.2 Biossinais do Corpo Humano

Os biossinais podem ser representados como séries temporais ou como imagens. Dentre os biossinais temporais gerados pelo corpo humano, pode-se citar os sinais de EMG, que captura e registra os potenciais de ação das células musculares, ECG, que registra a atividade elétrica do coração e EEG, responsável pela aferição dos campos elétricos gerados pelas sinapses do cérebro. Também pode-se citar como biossinais de imagem a ressonância magnética (RM), no qual são representados os campos magnéticos gerados pelo cérebro e tomografia por emissão de pósitrons, do inglês *positron emission tomography* (PET), onde é visualizada a emissão de isótopos radioativos em áreas do cérebro para determinar picos de atividades.


Os sinais elétricos provenientes dos neurônios podem ser medidos através de diferentes técnicas, como magnetoencefalografia (MEG) <sup>2</sup>, ou EEG. No caso do EEG, os sinais podem ser coletados através metodologias invasivas ou não invasivas. A coleta de EEG invasiva é feita através de eletrodos intracraniais cirurgicamente implantados, tanto no espaço epidural, subdural ou no parênquima (SHAH; MITTAL, 2014). A Figura 7 indica anatomicamente o espaço epidural e o espaço subdural.

O método não invasivo de coleta compreende a instalação de eletrodos no escalpo, de acordo com posições (montagens) específicas. O número pode variar até 256 eletrodos (NAJARIAN; SPLINTER, 2012), no entanto sua quantidade e seu posicionamento dependem prin-

<sup>2</sup> Método não invasivo de registro da atividade elétrica do cérebro, que utiliza sensores para medir os campos magnéticos gerados pelas correntes elétricas produzidas pelos neurônios cerebrais (PHILIP; PRASAD; HEMANTH, 2022).

principalmente do objetivo a ser atingido e das técnicas de processamento empregadas, podendo ser reduzido para até quatro eletrodos (JÚNIOR *et al.*, 2022) no caso da imagética motora.


**Figura 7 – Meninges e espaços do cérebro.**



Fonte: Adaptado de Mishra *et al.* (2020).

O posicionamento dos eletrodos no cérebro geralmente é dado de acordo com padrões pré-estabelecidos. O padrão mais comum é o padrão 10-20 (representado na Figura 8), onde ao topo da cabeça é dividida em dois hemisférios e cada eletrodo é posicionado de forma 20% mais espaçada que o primeiro. Cada eletrodo é nomeado de acordo com uma letra referente ao lobo cerebral ao qual corresponde e um número referente ao hemisfério e a distância do centro: Pares para a direita, ímpares para a esquerda (HOMAN; HERMAN; PURDY, 1987). A principal diferença entre os padrões é a resolução, ou seja, o número máximo possível de eletrodos presentes em cada posicionamento. No padrão 10-20, a resolução é de 21 eletrodos, enquanto que no padrão 10-10 (Figura 8, a resolução pode variar entre 64 e 81 eletrodos (JURCAK; TSUZUKI; DAN, 2007).

**Figura 8 – Sistemas de posicionamento de eletrodos.**



Fonte: Maskeliunas *et al.* (2016).

Os eletrodos também apresentam diferenças entre si. Eletrodos passivos são peças revestidas de metais condutores (prata ou ouro, por exemplo) que captam os bio-sinais através do

contato. No entanto, necessitam da aplicação de gel condutor para realizar a coleta adequada. Eletrodos ativos são peças que possuem circuitos que regulam a impedância dos eletrodos, diminuindo interferência de ruídos e dispensando a aplicação do gel condutor. Já os eletrodos secos são eletrodos fixados por meio de um capacete na cabeça, facilitando a implantação e dispensando também o uso de gel condutor. Por fim, os eletrodos esponja são eletrodos com alta aderência, que também não precisam de gel condutor e permitem a aplicação eficiente e rápida no indivíduo (SHAD; MOLINAS; YTTERDAL, 2020).

**Figura 9 – Eletrodo seco de ouro para EEG.**



**Fonte: CPAP Fit<sup>3</sup>.**

Os sinais de EEG geralmente são convertidos utilizando uma FT e caracterizados de acordo com as faixas de frequência (KUMAR; BHUVANESWARI, 2012). As principais faixas de frequência e suas nomenclaturas estão representadas na Tabela 1.

**Tabela 1 – Bandas de frequências de ondas do cérebro.**

Nome	Frequência (Hz)
Delta	0.1 ~ 4
Theta	4 ~ 8
Alpha	8 ~ 13
Beta	13 ~ 30
Gamma	30 ~ 100

**Fonte: Adaptado de Kumar e Bhuvaneshwari (2012).**

As ondas delta são principalmente encontradas em crianças e durante o sono de seres humanos em geral. As ondas theta são relacionadas às atividades do subconsciente e são observadas em seres humanos em estado de relaxamento profundo. Já as ondas alpha são

<sup>3</sup> Disponível em: <<https://www.cpapfit.com.br/eletrodos-de-ecg-5-unidades-72-in/p/5016>>. Acesso em 18 de maio de 2024.

encontradas principalmente em seres humanos acordados em estado de relaxamento, com olhos fechados. Ondas beta estão relacionadas a atividades comportamentais e aos sentidos, ocorrendo durante a execução de ações como raciocinar e falar. Finalmente, as ondas gamma estão associadas a estados de alerta e hiperatenção, integrando memória e sensações (KUMAR; BHUVANESWARI, 2012). Destas ondas, as mais importantes para o estudo da IM são as ondas alpha, beta e gamma, de acordo com Diez (2018).

### 2.2.3 Pré-processamento de Biossinais de Eletroencefalografia

Para que o sinal de EEG possa ser processado corretamente, é necessário ainda um pré-processamento, onde ocorre a filtragem, remoção de artefatos e extração de características. Dentre os diversos tipos de filtro aplicados aos sinais de EEG, os principais tipos são os filtros clássicos (passa-baixa, passa-alta e passa banda), filtros adaptativos (Wiener ou Bayes) ou mesmo transformadas *Wavelet* (URIGÜEN; GARCIA-ZAPIRAIN, 2015).

A remoção de artefatos <sup>4</sup> está relacionada ao tipo de artefatos que se deseja encontrar. A técnica de análise de componente independente, do inglês *independent component analysis* (ICA) pode ser aplicada para remoção de artefatos oculares e cardíacos (ANSARI *et al.*, 2023), bem como para remoção de artefatos motores (FRØLICH; DOWDING, 2018). Além da técnica de ICA, os métodos de transformada *Wavelet* (TW) e cancelamento de ruído adaptativo, do inglês *adaptive noise canceling* (ANC) também podem ser utilizados (ANSARI *et al.*, 2023).

Os métodos de extração podem ser separados em grupos diferentes, nominados gerações, de acordo com os domínios utilizados (SINGH; KRISHNAN, 2023). A primeira geração se trata de métodos aplicados no domínio do tempo, tais quais os métodos de dimensão fractal, do inglês *fractal dimension* (FD), para identificação de emoções (LIU; SOURINA, 2014), ou o método de auto regressão (AR) para classificação de artefatos de EEG (ZHANG; JI; ZHANG, 2015).

A segunda geração de algoritmos abrange os que são executados no domínio da frequência, como Densidade de Potência Espectral (TANG *et al.*, 2024) e transformada rápida de Fourier, do inglês *fast Fourier transform* (FFT) (HINDARTO; MUNTASA; SUMARNO, 2019), ambas para extração de características. Dentre as vantagens desses algoritmos, pode-se citar a baixa complexidade de implementação computacional.

A terceira geração compreende o domínio de decomposição, nos quais os métodos de transformadas *wavelet* contínuas e discretas ou decomposição de características em escala local, do inglês *local characteristic-scale decomposition* (LCD) podem ser utilizados para extração de características para classificação de doenças como demência (IERACITANO *et al.*, 2020) e também de imagética motora (LIU *et al.*, 2017).

<sup>4</sup> Artefatos são ruídos encontrados nos sinais coletados, como movimentos musculares involuntários, piscar de olhos e bater do coração (MUMTAZ; RASHEED; IRFAN, 2021).




Na quarta geração, o domínio abordado é tempo-frequência, que permite a extração de características para classificação utilizando métodos de busca correlata, do inglês *matching pursuit* (MP) e Transformada S (RUTKOWSKI; PATAN; LEŚNIAK, 2013).

Já na quinta e última geração classificada até o momento, estão os métodos do domínio do espaço, entre os quais está o CSP. O algoritmo CSP possui diversas variações que utilizam de outras características representativas do sinal, dentre elas: o padrão comum espaço-espectral, do inglês *common spatial-spectral pattern* (CSSP) (AGHAEI; MAHANTA; PLATANI-OTIS, 2016) e padrão comum esparso espaço-espectral, do inglês *common sparse spatial-spectral pattern* (SS-CSP). Embora essas duas variações do CSP apresentem melhorias em relação ao algoritmo base, sua complexidade computacional cresce de forma intensa, o que dificulta sua implementação em casos gerais.

O método CSP foi proposto por Koles, Lazar e Zhou (1990), e passou a ser utilizado constantemente na literatura para a extração de características. Basicamente, o método busca encontrar padrões comuns espaciais, ou seja, encontrar grupos que melhor discriminem a variância de dois conjuntos de sinais (BLANKERTZ *et al.*, ). A Figura ?? mostra uma representação de um *headplot* com uma área onde há um padrão espacial demarcado em vermelho.

**Figura 10 – Representação de um *headplot* de um CSP**




**Fonte: Autoria própria (2024).**

## 2.3 Interface cérebro-máquina

Uma BCI proporciona um canal de comunicação entre o cérebro humano e um dispositivo, geralmente um computador (PRASHANT; JOSHI; GANDHI, 2015). A BCI pode ser utilizada para a detecção, diagnóstico e tratamento de patologias do sistema nervoso, como convulsões, epilepsia, transtorno de déficit de atenção e hiperatividade (TDAH) (MILNE-IVES *et al.*, 2023), incapacidade motora proveniente de AVC ou lesões medulares, por exemplo. As principais fases de uma BCI são a aquisição de dados, processamento e classificação do sinal, interface do computador e aplicação, conforme mostra a Figura 11 (PRASHANT; JOSHI; GANDHI, 2015).



**Figura 11 – Representação do processo de uma interface cérebro-máquina.**



**Fonte: Autoria própria (2024).**

A aquisição consiste na medição, obtenção e armazenamento dos dados brutos desde a aplicação de eletrodos até a amplificação do sinal para que possa gerar valores processáveis para o computador. O processamento inclui a filtragem e a aplicação de métodos de extração de características e classificação de padrões. Essa fase pode gerar diferentes tipos de resultados, como classificações binárias ou tarefas multiclasse. Esses resultados são visualizados através de programas no computador e são enviados para outros aplicativos, próteses ou órteses.

A BCI pode ser projetada tendo em mente diversos objetivos, como restaurar o movimento de um membro, substituir um membro perdido através de uma prótese, aprimorar a experiência de jogo de um usuário, complementar um aspecto cotidiano (óculos de realidade aumentada), aperfeiçoar o funcionamento de um membro acometido de imparidade motora ou realizar pesquisas sobre o funcionamento do cérebro.

## **2.4 Aprendizado de Máquina**


Dentre os inúmeros métodos existentes de aprendizado de máquina que podem ser utilizados, os principais algoritmos e técnicas aplicados como classificadores são máquina de vetores de suporte, do inglês *support vector machine* (SVM), análise de discriminante linear, do inglês *linear discriminant analysis* (LDA), redes neurais artificiais, do inglês *artificial neural network* (ANN), 'k' Vizinhos próximos, do inglês '*k*' *nearest neighbours* (k-NN), distância de Mahalanobis, do inglês *Mahalanobis distance* (MD), classificador inocente de Bayes, do inglês *naive Bayes classifier* (NBC), modelo oculto de Markov, do inglês *hidden Markov model* (HMM) e outros modelos de DL (PAWAN; DHIMAN, 2023). Esses classificadores reconhecem padrões baseados em rótulos dados às janelas dos sinais de eletroencefalografia, e permitem realizar tanto classificações binárias como multiclasse.

Uma SVM é uma técnica que consiste em encontrar um hiperplano <sup>5</sup> separador otimizado que possa classificar um conjunto de dados, de modo que cada classe fique majoritariamente de um lado do hiperplano. Essa técnica consegue lidar com indivíduos fora do padrão,

<sup>5</sup> Considerando um espaço  $K$  de dimensão  $n$ , um hiperplano é um subespaço de dimensão  $n - 1$  que separa o espaço  $K$  em dois.

conhecidos como *outliers* e busca encontrar limites entre as duas classes, chamados de margens, de modo a minimizar o erro em novas classificações (JAMES *et al.*, 2013). Embora a SVM seja geralmente utilizada para a classificação de problemas linearmente separáveis, é possível utilizá-la em problemas não lineares, mediante a utilização de um *kernel*, uma função que aumenta a dimensionalidade de um problema para separá-lo linearmente em uma dimensão acima. A Figura 12 apresenta um exemplo gráfico de classificação binária utilizando um hiperplano.

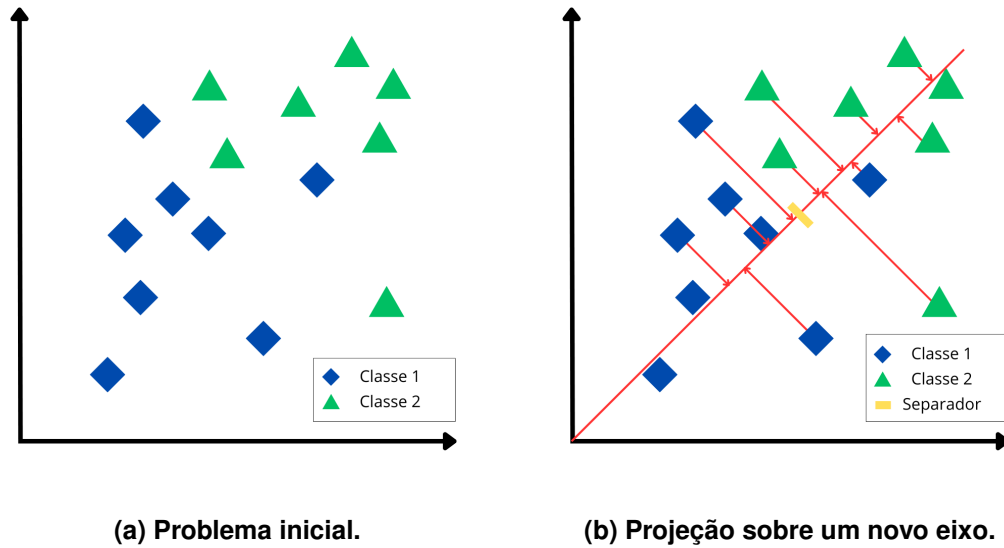
**Figura 12 – Exemplo gráfico de uma SVM linear.**



**Fonte: Autoria própria (2024).**

A técnica de LDA é principalmente utilizada para redução de dimensionalidade e classificação de problemas multiclasse e consiste em encontrar uma combinação linear dos dados que aumente a distância entre as médias dos valores e diminua a variância entre eles, de forma que os dados possam ser linearmente separáveis (HASTIE; TIBSHIRANI; FRIEDMAN, 2013). A Figura 13.a) representa um problema onde a projeção nos eixos X e Y não resulta em uma classificação ótima. Já a Figura 13.b) mostra um novo eixo (em vermelho) onde ocorre a projeção dos dados, de forma que possa ocorrer uma classificação melhor (em laranja).


**Figura 13 – Exemplo gráfico de uma LDA.**



Fonte: Autoria própria (2024).

O algoritmo de k-NN é um algoritmo classificador baseado na proximidade de uma amostra para com seus vizinhos mais próximos. A amostra é inserida em um conjunto de dados, e então, é calculada a sua distância Euclidiana dos seus  $k$  vizinhos mais próximos. Após isso, a amostra passa a pertencer à classe cuja maioria dos vizinhos pertença. Para que o algoritmo funcione, é recomendado que o valor  $k$  escolhido seja um valor ímpar, para que haja uma diferença entre o número de classes (KUBAT, 2015). A representação gráfica na Figura 14 exemplifica a classificação em um algoritmo k-NN: a amostra quadrada, em preto, possui mais vizinhos da classe 2 do que vizinhos da classe 1, logo, seria classificada como classe 2 no caso desse algoritmo.

**Figura 14 – Exemplo gráfico de um kNN.**

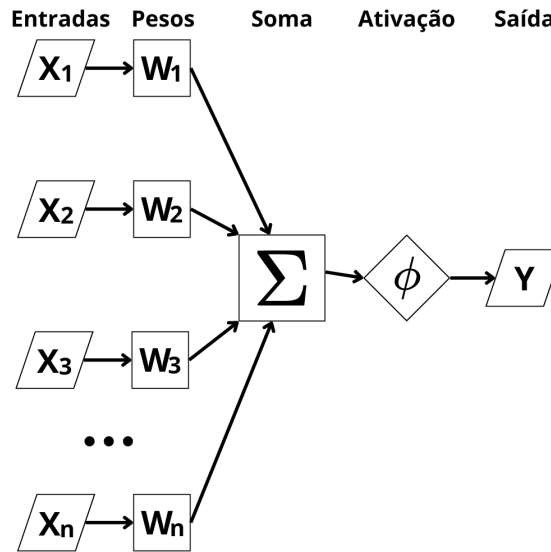


**Fonte: Autoria própria (2024).**

Para Simon Haykin, "uma rede neural é uma máquina projetada para modelar a forma que o cérebro humano realiza uma tarefa em particular ou função de interesse"<sup>6</sup> (HAYKIN, 1999). Essa visão se iniciou em 1943, quando Warren McCulloch e Walter Pitts desenvolveram um modelo de neurônio artificial (representado na Figura 15), capaz de computar e implementar funções e conectivos lógicos através da interligação desses neurônios, criando redes (RUSSELL; NORVIG, 2021). Após isso, em 1949, Donald Hebb demonstrou uma regra de atualização dos pesos, que permitia que os neurônios aprendessem, permitindo a regulação da força das sinapses. A partir dessa estrutura, foram desenvolvidos modelos de redes neurais artificiais, algoritmos que são capazes de classificar e compreender problemas mais complexos. Entre os diferentes tipos de redes neurais, podem-se citar a rede neural convolucional, do inglês *convolutional neural network* (CNN), rede neural recorrente, do inglês *recurrent neural network* (RNN) e Perceptron multi camadas, do inglês *multi-layer Perceptron* (MLP).

<sup>6</sup> Tradução Livre: *In its most general form, a neural network is a machine that is designed to model the way in which the brain performs a particular task or function of interest.*

Figura 15 – Modelo do Neurônio de McCulloch-Pitts.



Fonte: Autoria própria (2024).

Conforme o número de camadas intermediárias em uma rede aumenta, o emaranhado complexo de matrizes cria um sistema de DL, conhecido como rede neural profunda, do inglês *deep neural network* (DNN). Essas redes são capazes de resolver problemas extremamente complexos, no entanto necessitam de conjuntos de dados extensos para serem treinadas e de uma grande capacidade de processamento computacional, o que pode fazer com que seu processo de treino não seja tão eficiente em problemas simples (RUSSELL; NORVIG, 2021). Uma das principais características das redes de DL é a capacidade de abstrair as informações através de suas matrizes de peso. Isso permite que, em modelos de aprendizado profundo, as etapas e métodos de extração de características sejam atrelados à própria rede, tornando-as modelos robustos, porém fechados, nos quais os dados podem ser inseridos em sua forma bruta, conforme ilustra a Figura 16.

Figura 16 – Diferença entre *pipelines* de processamento.  
Métodos Convencionais

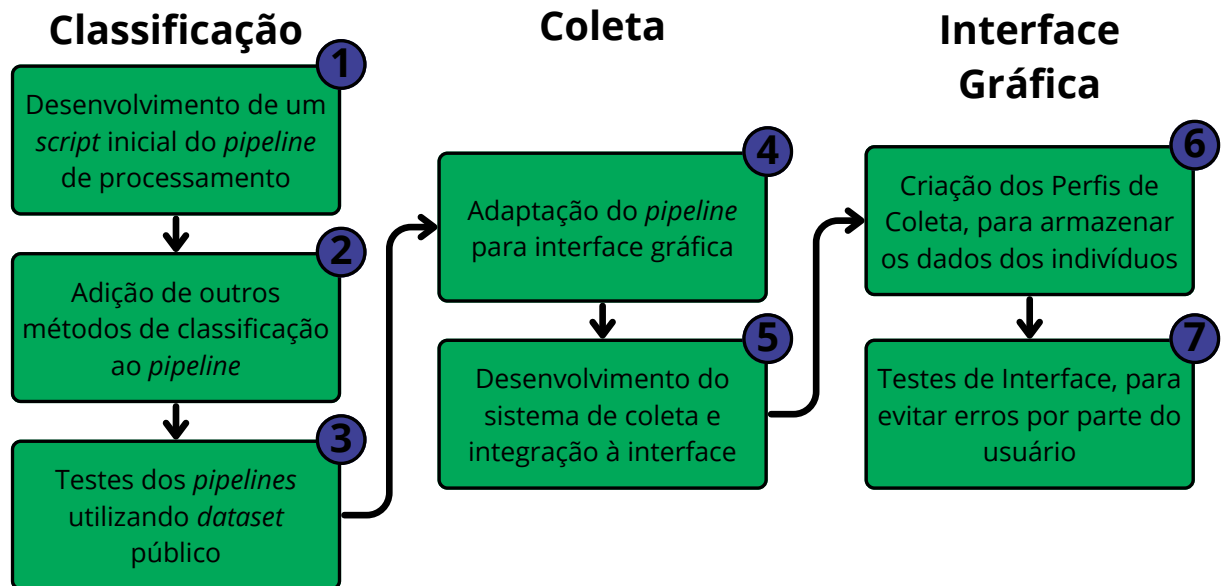


Fonte: Autoria própria (2024).

### 3 MATERIAIS E MÉTODOS

Este trabalho foi desenvolvido seguindo o fluxo apresentado na Figura 17, sendo dividido em três partes principais: o desenvolvimento do *pipeline* de classificação, a criação da interface gráfica e o desenvolvimento do sistema de coleta de dados de EEG. As etapas descritas no fluxograma estão numeradas de acordo com a ordem de execução.

Figura 17 – Fluxograma de desenvolvimento do trabalho



Fonte: Autoria própria (2024).

#### 3.1 Classificação

O início do projeto se deu com o desenvolvimento de um *script* básico, utilizando CSP e LDA para classificação de padrões de IM. A base para o desenvolvimento foi um *script*<sup>1</sup> encontrado na documentação da biblioteca **MNE**, desenvolvida por Gramfort *et al.* (2013). Esse *script* utiliza o *dataset EEG Motor Movement/Imagery Dataset* (SCHALK *et al.*, 2004)<sup>2</sup>, que possui coletas de dados de IM de 109 indivíduos diferentes. De acordo com a descrição do *dataset*, cada indivíduo realizou 14 sessões de coleta, nas quais desenvolveu diferentes tarefas de IM, conforme mostrado na tabela 2. Cada uma das sessões foi armazenada em um arquivo .edf diferente. Para este trabalho foram utilizados dados de todos os 109 indivíduos, exclusivamente das sessões sem o aspecto físico do movimento, apenas considerando a intenção (sessões 4, 6, 8, 10, 12 e 14). De acordo com os criadores do *dataset*, a coleta foi realizada com 64 canais

<sup>1</sup> Disponível em <[https://mne.tools/dev/auto\\_examples/decoding/decoding\\_csp\\_eeg.html](https://mne.tools/dev/auto_examples/decoding/decoding_csp_eeg.html)>. Acesso em 03/01/2024.

<sup>2</sup> Disponível em: <<https://physionet.org/content/eegmmidb/1.0.0/>>. Acesso em 15 de janeiro de 2024.

seguindo o sistema de montagem internacional 10-10, com uma taxa de amostragem de 160 Hz e as sessões duraram três minutos cada.

**Tabela 2 – Descrição das tarefas utilizadas em cada sessão.**

Sessão	Descrição
1	Coleta base, com os olhos abertos.
2	Coleta base, com os olhos fechados.
3, 7, 11	Um alvo aparece no lado esquerdo ou direito da tela e o indivíduo abre e fecha o punho correspondente até que o alvo desapareça.
4, 8, 12	Um alvo aparece no lado esquerdo ou direito da tela e o indivíduo <b>imagina</b> abrir e fechar o punho correspondente até que o alvo desapareça.
5, 9, 13	Um alvo aparece na parte superior ou inferior da tela e o indivíduo abre e fecha ambos os punhos (se o alvo estiver na parte superior) ou ambos os pés (se o alvo estiver na parte inferior) até que o alvo desapareça.
6, 10, 14	Um alvo aparece na parte superior ou inferior da tela e o indivíduo <b>imagina</b> abrir e fechar ambos os punhos (se o alvo estiver na parte superior) ou ambos os pés (se o alvo estiver na parte inferior) até que o alvo desapareça.

**Fonte: Adaptado de Schalk *et al.* (2004).**

Neste *script* foi utilizado um filtro Firwin com janela de Hamming, para realizar a filtração inicial dos dados presentes no *dataset*. O *script* então foi adaptado para funcionar com as sessões escolhidas. Após essa etapa, foram inseridos no *script* os algoritmos de SVM, k-NN e MLP, para que pudessem ser inseridos no *pipeline* de processamento. Todos os métodos citados possuem hiperparâmetros *default*, conforme descrito na documentação respectiva. Os hiperparâmetros *default* do método CSP estão presentes na Tabela 3. Alguns valores, por dependerem do desenvolvimento direto de funções em *Python* foram mantidos de fora, sem possibilitar a alteração por parte do usuário da aplicação.

**Tabela 3 – Hiperparâmetros *default* do método CSP.**

Hiperparâmetro	Valor	Tipo
n_components	4	Integer
reg	None	None ou String
log	None	None ou Boolean
cov_est	concat	String
transform_into	average_power	String
norm_trace	False	Boolean

**Fonte: Autoria própria (2024).**

A Tabela 4 apresenta os hiperparâmetros *default* dos métodos de classificação, conforme o indicado na documentação da biblioteca **scikit-learn** (PEDREGOSA *et al.*, 2011).

Após a inserção dos algoritmos no *script*, foram realizados três experimentos de classificação de padrões em todos os 109 indivíduos para determinar qual a melhor banda de frequên-

**Tabela 4 – Hiperparâmetros *default* dos métodos de classificação.**

Método	Hiperparâmetro	Valor	Tipo
LDA	solver	svd	String
	shrinkage	None	None, String ou Float
	n_components	None	None ou Int
	store_covariance	true	Boolean
	tol	0.0001	Float
SVM	C	1.0	Float
	kernel	rbf	String
	degree	3	Integer
	gamma	scale	String ou Float
	coef0	0.0	Float
	shrinking	true	Boolean
	probability	false	Boolean
	tol	0.001	Float
	cache_size	200.0	Float
	max_iter	-1	Integer
MLP	hidden_layer_sizes	100	Integer
	activation	relu	String
	solver	adam	String
	alpha	0.001	Float
KNN	n_neighbors	5	Integer
	weights	uniform	String
	algorithm	auto	String
	leaf_size	30	Integer

**Fonte: Autoria própria (2024).**

cia para o filtro do sinal e qual a melhor janela de tempo a ser utilizada, bem como para avaliar o desempenho médio dos métodos de classificação implementados.

No primeiro experimento, foram testadas diferentes faixas de frequência no filtro Firwin implementado. As faixas de frequência variavam seguindo a seguinte regra: a frequência superior (frequência de corte do filtro passa-baixa) deveria variar de 5 Hz a 49 Hz, em incrementos de 1 Hz, enquanto a frequência inferior (frequência de corte do filtro passa-alta) deveria variar de 0 Hz até a frequência superior, também em incrementos de 1 Hz. No total, foram testadas 1215 bandas de frequência. De acordo com Diez (2018), as frequências relevantes para a classificação de sinais de IM estão entre 8 Hz e 30 Hz, por isso foram testados os valores com uma margem maior, compreendendo faixas de frequência entre 0 Hz e 49 Hz. A classificação neste experimento ocorreu utilizando um *pipeline* contendo os métodos de CSP e LDA, com os parâmetros *default* já apresentados, que foi validado através da função de validação cruzada da biblioteca **scikit-learn**, com 50 iterações utilizando 20% das amostras para teste.

Para realizar o segundo experimento, um processo similar foi adotado, mantendo o mesmo *pipeline* e a mesma função de validação. O intervalo de tempo foi determinado através de um valor máximo e um mínimo de tempo para iniciar e terminar o intervalo. O tempo máximo variou de 0,1 segundos a 3,9 segundos, enquanto o tempo mínimo variou de 0,0 ao



valor do tempo máximo da iteração, já que um tempo mínimo maior que o máximo não faria sentido.

Estes experimentos foram realizados pois nesta versão do programa, a banda de frequência do filtro (bem como o próprio filtro) e a faixa de tempo de janelamento são hiperparâmetros fixos, sem que o usuário possa alterá-los. Por esta razão, identificar os valores mais adequados é necessário a fim de maximizar os resultados obtidos pelo algoritmo.

### 3.2 Coleta de Dados


Foi desenvolvido nessa etapa um *script* para realizar a coleta de dados de EEG. O código utiliza a biblioteca **BrainFlow** para identificar a placa de coleta conectada ao computador e configurar a recepção do sinal. A coleta de dados foi dividida em duas partes: implementação lógica e *setup* físico. Para configurar a parte lógica de uma coleta, é necessário determinar qual tipo de resolução vai ser utilizada, o número de eletrodos a ser inserido e quais eletrodos serão usados, além de qual placa será utilizada para realizar a coleta e qual porta USB do computador a placa está conectada. O *setup* físico compreende a utilização da touca com os eletrodos, a conexão dos eletrodos à placa de coleta e a transmissão de dados da placa até o *script* desenvolvido.

Para testar o sistema de coleta, foi utilizada a placa *OpenBCI Cyton* (Figura 18.a)<sup>3</sup>, conectada via *Bluetooth* através do dispositivo *OpenBCI USB Dongle* (Figura 18.b). Por padrão, a placa possui frequência de amostragem de 250 Hz e diversas configurações de coleta, permitindo coleta de bio-sinais de EMG, ECG e EEG. Dado o escopo deste trabalho, foi utilizada a configuração de EEG para a coleta de IM, conforme instruções de montagem presentes na documentação disponível online<sup>4</sup>.

<sup>3</sup> Disponível em: <<https://shop.openbci.com>>. Acesso em 22 de maio de 2024.

<sup>4</sup> Disponível em: <<https://docs.openbci.com/Examples/EEGProjects/MotorImagery/>>. Acesso em 23 de setembro de 2023

**Figura 18 – Equipamentos utilizados na coleta de dados.**



**(a) Placa OpenBCI Cyton**

**(b) Dispositivo OpenBCI USB Dongle**

Fonte: Imagens retiradas da Internet.

Embora a placa se conectasse normalmente, não foram coletados dados reais de nenhum indivíduo, pois não há comitê de ética que permita a coleta de dados para esse trabalho. Todos os dados coletados foram obtidos a partir dos eletrodos flutuantes, com a finalidade de testar a capacidade do *script* de receber dados da placa e salvá-los em um arquivo .CSV.

Também nesse mesmo *script*, foi criado um banco de dados de documentos (JSON) utilizando a biblioteca **TinyDB**<sup>5</sup>, para que pudessem ser criados Perfis de Coleta, onde ficariam salvas as configurações lógicas da coleta de cada indivíduo. As informações de cada indivíduo estão presentes na Tabela 5.

**Tabela 5 – Informações presentes no banco de dados JSON.**

<b>Campo</b>	<b>Descrição</b>
Nome	Nome do arquivo de coleta que será gerado.
Descrição breve	Descrição do indivíduo, da tarefa de imagética realizada e outras observações relevantes.
Resolução	Sistema de posicionamento de eletrodos que será utilizado para as coletas desse indivíduo
Nº de Canais	Quantidade de canais a serem utilizados na coleta de EEG.
Canais	Lista com o nome de todos os canais que serão utilizados na coleta.
<i>Runs</i>	Número de execuções da tarefa de imagética motora por coleta.
<i>Rest</i>	Tempo de descanso entre estímulos visuais/sonoros.
MI	Tempo de duração do estímulo visual.

Fonte: Autoria própria (2024).

<sup>5</sup> Documentação disponível em: <<https://tinydb.readthedocs.io/en/latest/>>. Acesso em 14 de abril de 2024.

O campo "Nome" geralmente não possui o nome do indivíduo que realizou as tarefas de imagética motora, por questões de privacidade. Idealmente, esse campo será preenchido com um código que represente o indivíduo.

### 3.3 Interface

Finalizado o desenvolvimento dos *scripts* foi criada uma interface gráfica de usuário, do inglês *graphical user interface* (GUI), com a biblioteca **PySimpleGUI** <sup>6</sup>, para permitir a criação de *pipelines* de classificação e a coleta de dados, possibilitando que pessoas que não possuem conhecimento de programação possam ter acesso aos métodos de ML para classificação de sinais de EEG. A GUI possui uma janela inicial dividida em duas partes: "Classificação" e "Coleta".

Na parte de coleta, o usuário do sistema primeiramente deve ter selecionado um Perfil de Coleta, para que a aplicação saiba quais configurações de coleta serão utilizadas e em qual arquivo salvar os dados coletados. Após isso, o usuário que estiver operando o sistema deve conectar o dispositivo *Dongle* da placa de coleta ao computador, apertar o botão de atualizar e selecionar a porta no qual o dispositivo está conectado (o computador detecta automaticamente as portas USB com dispositivos de coleta reconhecidos pela aplicação). Por último, o usuário deve dizer qual placa está conectada. Essas opções foram criadas para que futuramente, outros modelos de dispositivos de coleta possam ser utilizados. Ao lado do botão "Iniciar Coleta" há um botão para ativar ou desativar estímulos sonoros. Abaixo desse botão há uma imagem que representa o estado atual do processo de coleta de dados de IM. Essa imagem possui três modos diferentes, conforme mostrado na Figura 19.

Figura 19 – Imagens do sistema de coleta.



Fonte: Autoria própria (2024).

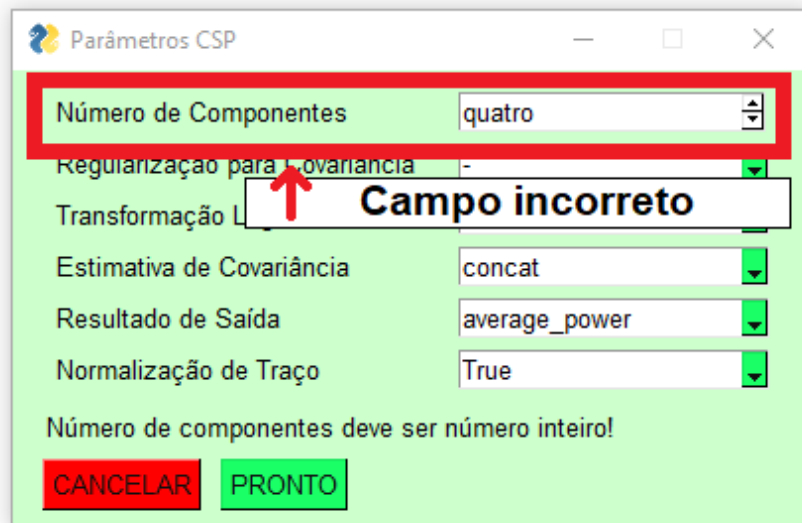
Ao clicar no botão "Iniciar Coleta", é criada uma *thread* para o processamento paralelo. Isso possibilita que a interface seja atualizada mostrando os estímulos visuais e sonoros, enquanto a *thread* coleta os dados e salva no arquivo.

<sup>6</sup> Foi utilizada a versão 4.59.0 da biblioteca, pois após a versão 5.0.0 a licença de uso passou a ser paga.

A parte de classificação foi estruturada conforme a lógica de criação de um *pipeline*: primeiramente, o usuário do programa insere o arquivo contendo os dados que serão utilizados. Este arquivo pode ser nos formatos .CSV, .EDF ou .FIF, que são os principais formatos utilizados pela biblioteca **MNE**. Após inserir o arquivo contendo os dados, o usuário pode inserir o método de extração de características e de classificação. As janelas de inserção de métodos ao *pipeline* são feitas como janelas modais criadas em arquivos separados. Dessa forma, novos métodos podem ser implementados facilmente através desse sistema modular. Nessa seção do programa há também um console onde é possível ver os parâmetros dos métodos inseridos bem como o resultado da classificação após esta ser executada. Abaixo do console, existem três botões: "Ver pipeline", "Executar" e "Ver gráficos". O primeiro permite que o usuário da aplicação veja o *pipeline* criado e remova os métodos inseridos caso deseje. O segundo botão inicia a execução do *pipeline* configurado e mostra no console a acurácia obtida. O terceiro botão apresenta a matriz de confusão da última classificação executada.

Ao adicionar um método ao *pipeline*, é criada uma janela modal para configurar os hiperparâmetros do método selecionado. Foi implementado um sistema de validação sobre os formulários presentes nessas janelas, para garantir que os usuários preenchessem as configurações dos métodos de acordo com as especificações corretas. Esse sistema impede o envio de informações incorretas e orienta o usuário sobre qual o tipo de dado a ser inserido em cada hiperparâmetro. Durante o desenvolvimento, duas estratégias foram abordadas: a primeira, utilizada na janela de configuração de CSP, permite que os usuários insiram quaisquer tipos de dados no campo de formulário e valida apenas no final, ao ser pressionado o botão "Pronto" mostrando o erro de execução (Figura 20). Essa estratégia foi substituída por outra abordagem nos métodos de classificação, que valida o dado a ser inserido a cada caractere digitado. Com essa segunda forma, o usuário não é capaz de digitar letras em campos numéricos, por exemplo. Ambas estratégias foram testadas como válidas e funcionais e foram mantidas na aplicação.

**Figura 20 – Erro ao inserir parâmetro de CSP.**



Fonte: Autoria própria (2024).

A Figura 21 apresenta a primeira versão da janela modal de hiperparâmetros do método de CSP. Por ser um design de testes, não houve preocupação com a tradução dos nomes de variáveis. Após o desenvolvimento de toda a interface, foram alterados os nomes para facilitar a compreensão do usuário do programa. Também foram adicionados *tooltips* explicando a função de cada campo, dado que não foi mantida a versão original do nome das variáveis.

**Figura 21 – Interface gráfica de teste para inserção de parâmetros de CSP.**

c_comp	4
reg_cov	-
log	-
cov_est	concat
transform_into	average_power
norm_trace	True

Fonte: Autoria própria (2024).

Considera-se importante citar que o *pipeline* é uma classe da biblioteca **scikit-learn**, onde é inserida uma lista de métodos a serem executados em ordem. Para que esses métodos possam ser inseridos e executados com sucesso, estes devem possuir obrigatoriamente em sua estrutura as funções *fit* e *transform*. Essa consideração permite que novos métodos sejam criados e testados também nessa interface.

4 RESULTADOS

4.1 Classificação

Para determinar se as acurácias obtidas durante os experimentos são satisfatórias, foram utilizados os resultados dos trabalhos presentes na Tabela 6. Foram considerados como ótimas as acurácias médias maiores que 80% para os métodos de SVM e LDA, maiores que 75% para k-NN e maiores que 90% para MLP. O caso base adotado para este trabalho foi o de chutes aleatórios, onde estatisticamente o modelo acerta 50% das vezes.

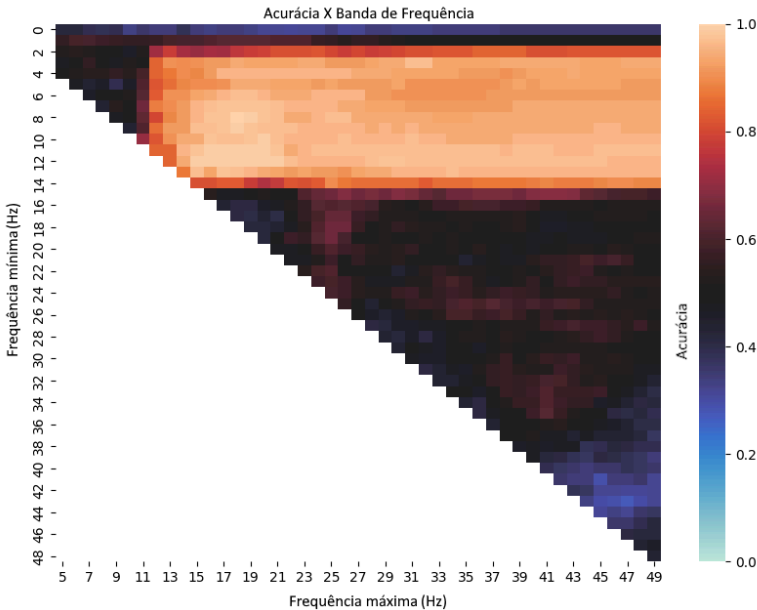
Tabela 6 – Comparação de Acurácia dos métodos de ML

Trabalho	Método	Acurácia Média
Sharma, Kim e Gupta (2022)	SVM	80.00%
	KNN	72.50%
	MLP	92.50%
Lazcano-Herrera, Fuentes-Aguilar e Alfaro-Ponce (2021)	SVM Linear	81.70%
	LDA	80.00%
	KNN	83.30%

Fonte: Autoria própria (2024).

Nos experimentos realizados a fim de encontrar valores ideais para a filtragem e janelamento do sinal, foram constatados dois fatos sobre os valores encontrados. Conforme mostrado no mapa de calor apresentado na Figura 22, foi encontrada uma região de faixas de frequência onde os valores de acurácia aumentam. Isso indica um conjunto de faixas de frequências específicas que contém informações relevantes sobre a imagética motora.

Figura 22 – Bandas de Frequência com melhores acurácias em laranja.

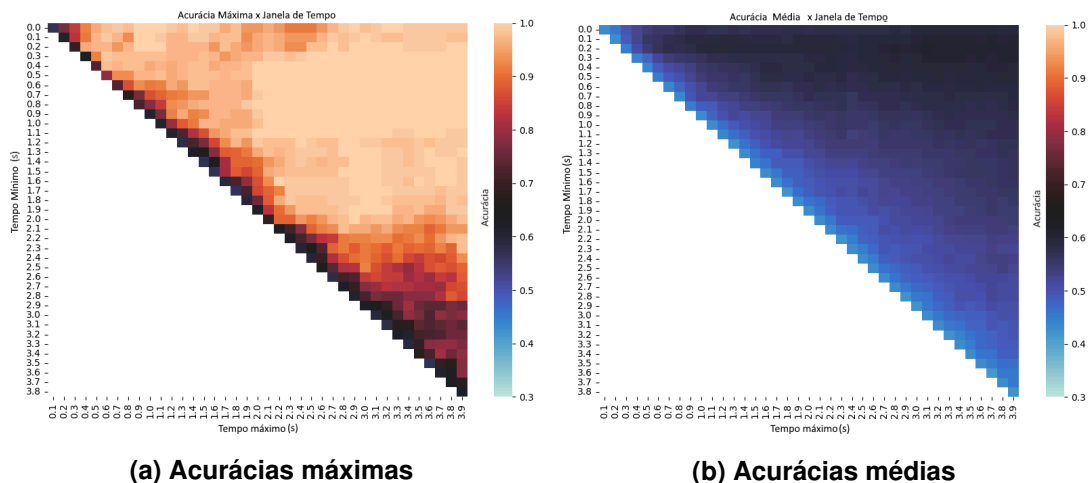


Fonte: Autoria própria (2024).

Essas informações relevantes se encontram entre os valores mínimos de 4  $Hz$  e 12  $Hz$  e os valores máximos maiores que 13  $Hz$ . Isso compreende as ondas theta (4  $Hz \sim 8 Hz$ ), alpha (8  $Hz \sim 13 Hz$ ) e beta (13  $Hz \sim 30 Hz$ ) dos sinais de EEG. Essas informações condizem com os valores presentes na literatura (DIEZ, 2018).

Com relação às janelas de tempo testadas, pode-se verificar que para todos os indivíduos testados, em janelas de tempo menores que 0,2 segundos, as acurácias obtidas não demonstraram valores satisfatórios, conforme representado na Figura 23.a). Para as janelas de tempo maiores que 0,2 segundos, é possível verificar através desta mesma figura que as acurácias diminuem de valor conforme o janelamento é realizado próximo ao final do evento (janelas que começam a partir de 2,5 segundos). Embora a acurácia média no geral tenha sido apenas levemente melhor que o caso base, ainda é possível notar a melhora nos resultados médios obtidos com faixas de tempo maiores, como mostrado na região mais escura da Figura 23.b).

**Figura 23 – Acurácias obtidas a partir dos experimentos realizados com janelas de tempo.**

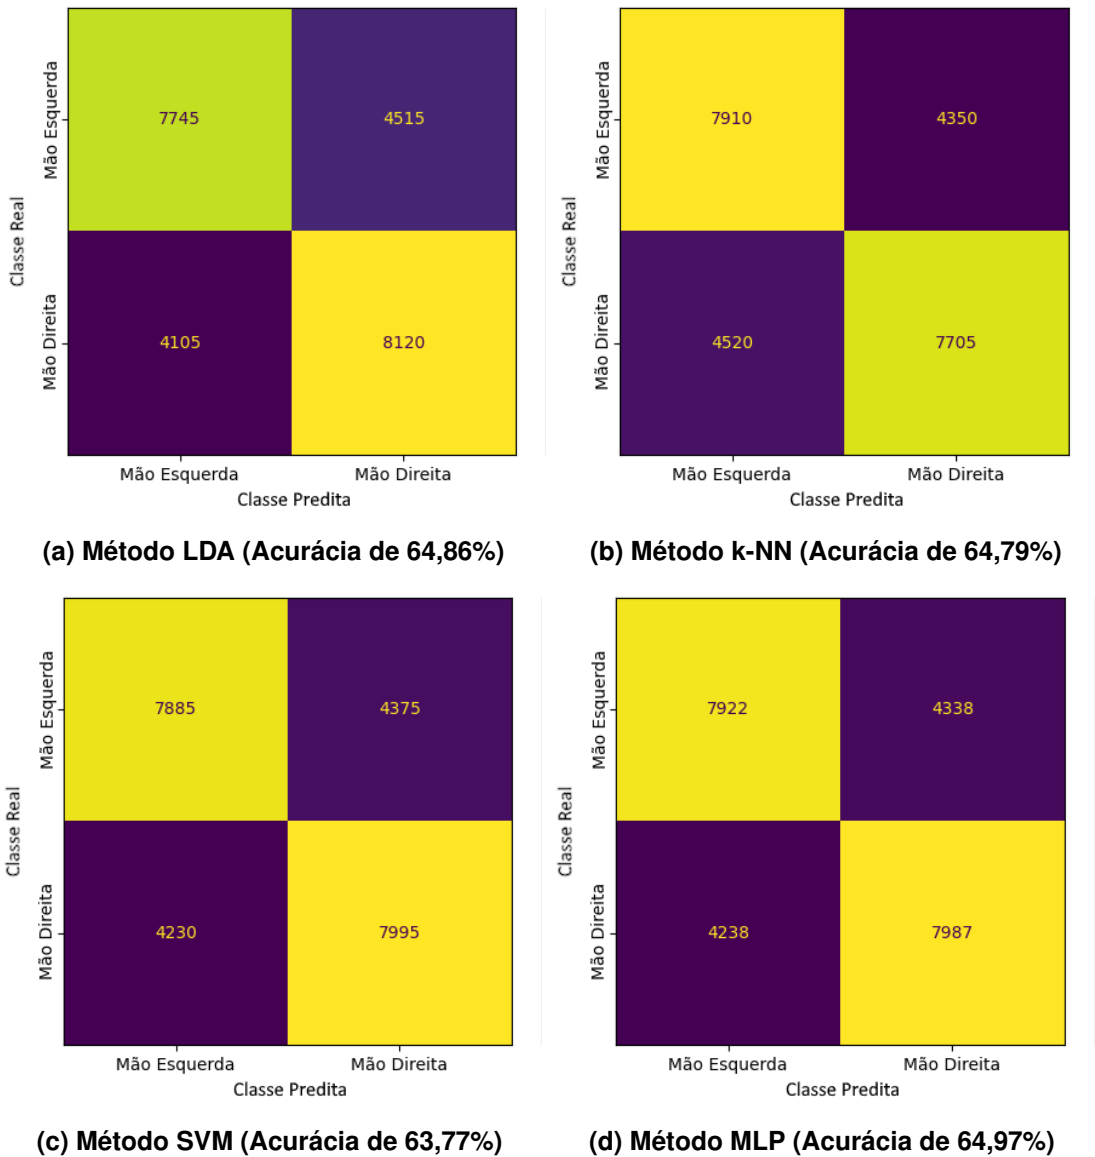


Fonte: Autoria própria (2024).

Na Figura 24, estão representadas as matrizes de confusão após a execução de cada algoritmo em todas as execuções de cada um dos indivíduos. Pode-se notar que em quase todos os algoritmos houve mais acertos em relação à mão direita do que da mão esquerda.

A acurácia média de cada um desses algoritmos pode ser vista ao lado do nome do método na legenda. O método que apresentou melhor desempenho no geral foi o MLP, com 64,97% de acurácia, enquanto o método SVM apresentou a menor acurácia, com 1,2 pontos percentuais a menos (63,77%).

Figura 24 – Matrizes de confusão de cada algoritmo.



Fonte: Autoria própria (2024).

Também foram escolhidos quatro indivíduos distintos do *dataset*, para analisar casos específicos e verificar se as características gerais encontradas na análise inicial são iguais em todos os indivíduos de forma separada. Foram testados os indivíduos 1, 2, 3 e 4 do *dataset*. Os resultados referentes à acurácia e desvio padrão estão apresentados na tabela 7. Os algoritmos com melhor acurácia e menor desvio padrão em cada indivíduo estão destacados em negrito.

Tabela 7 – Acurácia média e desvio padrão dos diferentes métodos de classificação.

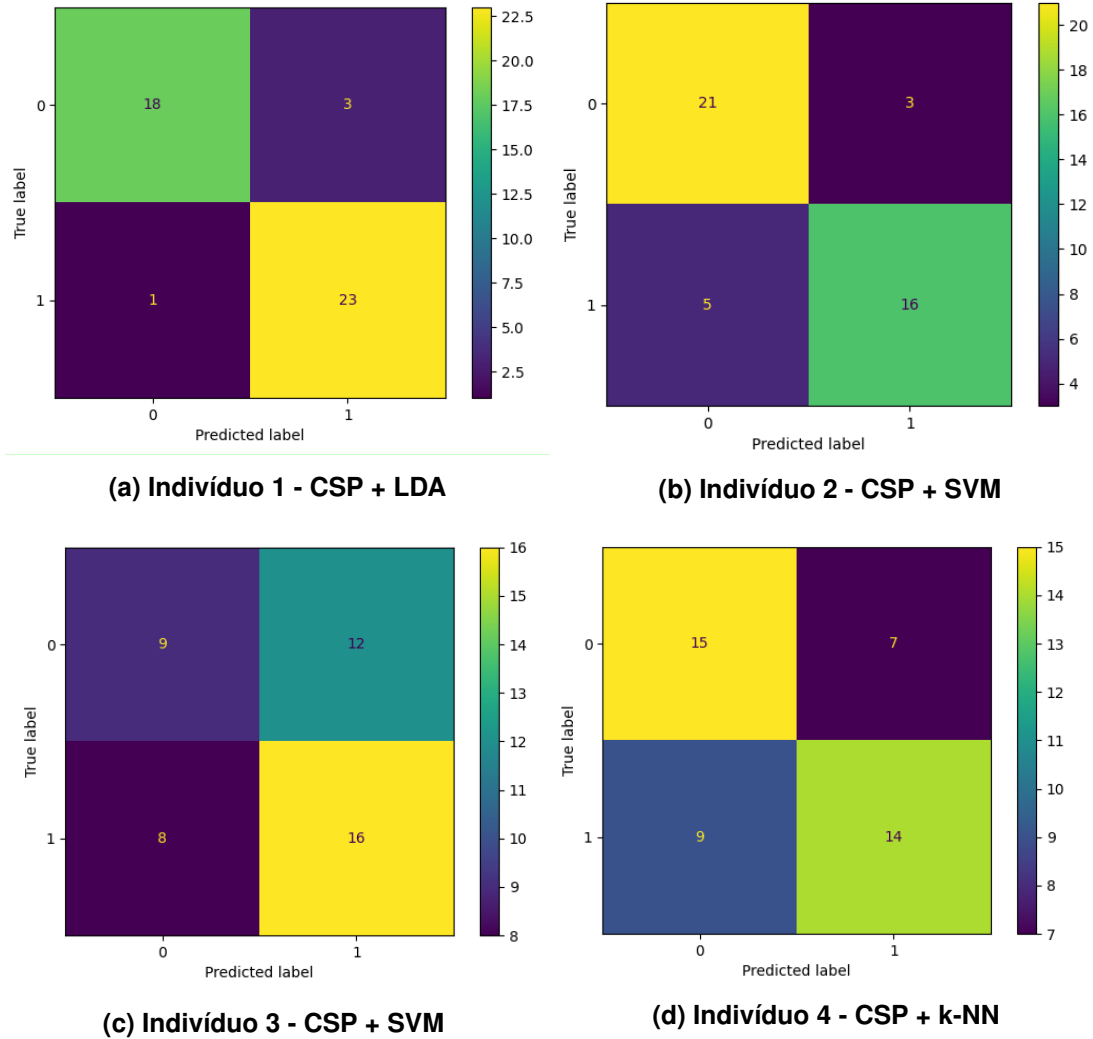
	LDA	k-NN	SVM	MLP
Indivíduo 1	<b>0.93 (0.07)</b>	0.92 (0.08)	0.93 (0.09)	0.92 (0.08)
Indivíduo 2	0.69 (0.02)	0.70 (0.19)	<b>0.75 (0.18)</b>	0.66 (0.23)
Indivíduo 3	0.42 (0.14)	0.51 (0.16)	<b>0.54 (0.13)</b>	0.49 (0.16)
Indivíduo 4	0.72 (0.16)	<b>0.80 (0.13)</b>	0.76 (0.12)	0.69 (0.16)

Fonte: Autoria própria (2024).



Pode-se observar que o desempenho dos algoritmos é limitado quando aplicado a determinados indivíduos, como é o caso do indivíduo número 3. Estes testes, no entanto, foram realizados utilizando os hiperparâmetros *default* das bibliotecas, sem a realização do ajuste fino.

**Figura 25 – Matrizes de confusão dos melhores algoritmos para cada indivíduo.**



Fonte: Autoria própria (2024).

Para avaliação dos erros, foi utilizada uma matriz de confusão, de forma a verificar onde os algoritmos mais erravam durante a classificação. Essa matriz de confusão compara a classificação do evento de mão esquerda com o de mão direita. Os rótulos foram mantidos como 0 e 1 na figura pois o tipo de evento pode variar de acordo com a coleta executada.

Tanto pela tabela quanto pelas matrizes de confusão apresentadas na Figura 25, é notável que as características da coleta do indivíduo modificam grandemente o resultado. No caso do indivíduo 1, todas as classificações geraram resultados satisfatórios, acima de 92% de acerto, enquanto para o indivíduo 3, dois métodos geraram resultados piores do que o caso base. Porém, tanto neste indivíduo como no indivíduo 2, que apresentou resultados próximos de 70%, foi possível notar que o algoritmo SVM apresentou os melhores resultados.

**Tabela 8 – Scores dos modelos selecionados.**

	Acurácia	Precisão	Recall	F1-Score
Indivíduo 1	91,11%	88,46%	75,00%	81,18%
Indivíduo 2	82,22%	84,21%	37,50%	51,89%
Indivíduo 3	55,56%	57,14%	60,00%	58,54%
Indivíduo 4	64,44%	66,67%	43,75%	52,83%

**Fonte: Autoria própria (2024).**

O alto *recall* nos indivíduos 1 e 3 aponta que os modelos utilizados possuíram mais acertos para a classificação do evento 1 (mão direita) do que para o evento 0 (mão esquerda). Já nos indivíduos 2 e 4, houve a maior prevalência da imagética da mão esquerda sobre a imagética da mão direita. Infere-se que essas diferenças podem ser fruto de fatores externos ao modelo, como o lado dominante do indivíduo, levantando a hipótese de que indivíduos destros podem imaginar de forma menos clara movimentos da mão esquerda, bem como indivíduos canhotos podem imaginar de forma menos clara movimentos da mão direita.

## 4.2 Coleta de Dados

Foi possível realizar coletas com eletrodos flutuantes, gerando arquivos .CSV utilizáveis nos *pipelines* de processamento desenvolvidos anteriormente. Os arquivos são criados juntamente com o Perfil de Coleta. A Figura 26 apresenta o arquivo de saída, contendo uma *timestamp*, os canais coletados e os gatilhos dos eventos de estímulos.

**Figura 26 – Arquivo de coleta com eletrodos flutuantes**

```

UsuarioApresentacao.csv
timestamp,Fp1,Fp2,C3,C4,events
0.0,0.0,0.0,0.0,0.0,1.0
0.016989469528198242,-158286.53821784715,-21748.33676199159,14734.404055405148,-155729.78922483794,0.0
0.020015954971313477,-158008.99660694558,-21444.978886244167,15050.033038858539,-155426.31959036822,0.0
0.023957014083862305,-157846.92410790018,-21292.987023948077,15213.893677460395,-155279.87096069707,0.0
0.028173208236694336,-158121.93997167828,-21575.8930535189,14921.421101262702,-155579.13846720918,0.0
0.03107619285583496,-158294.18251445086,-21771.806093669664,14715.069796451307,-155786.2273795876,0.0
0.03503751754760742,-158068.22872975215,-21517.55500049055,14980.317947902437,-155531.14927186363,0.0
0.039171457290649414,-157834.13891007172,-21289.746021002058,15220.889773474906,-155309.2188011669,0.0
0.043177127838134766,-158061.1655785043,-21517.711462701736,14988.744555562087,-155552.33872560726,0.0

```

**Fonte: Autoria própria (2024).**

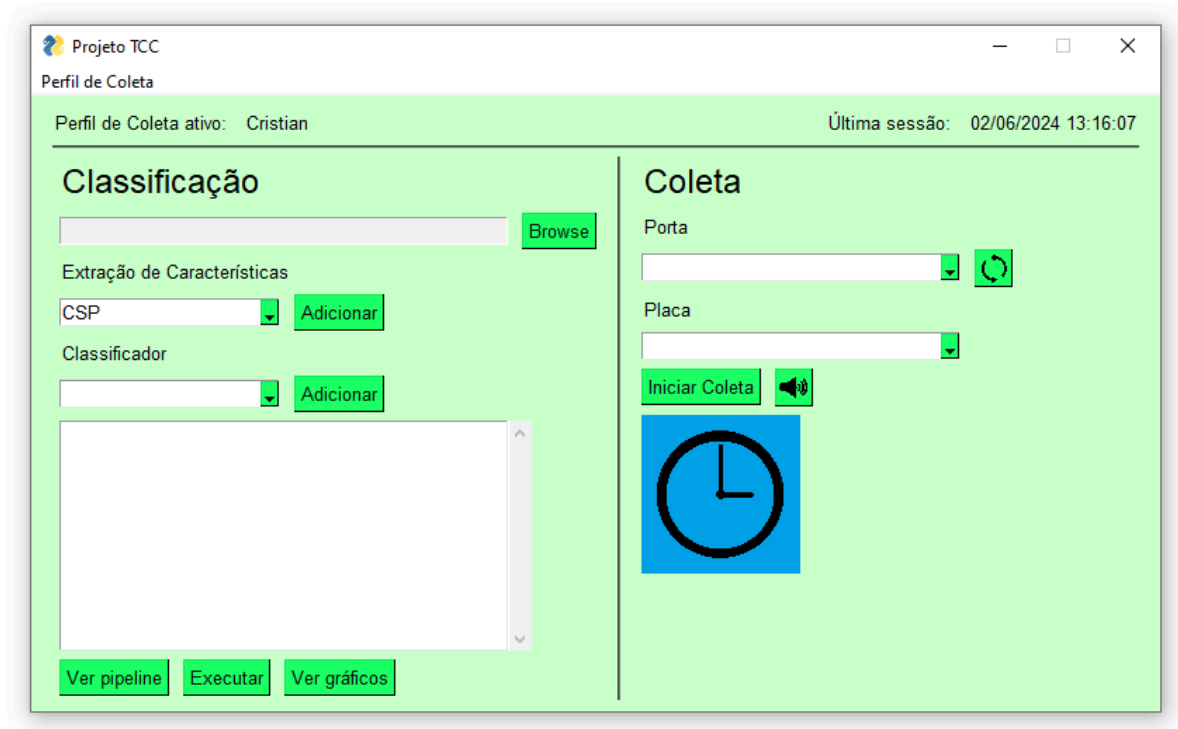
No arquivo gerado por essa coleta foi verificado que a taxa de amostragem não correspondeu exatamente a 250 Hz, pois haviam 247 amostras no período de 1 segundo. Essa diferença pode ser causada por diversos fatores, como por exemplo travamentos na *thread* de execução ou *delays* relacionados à lógica de implementação.

O arquivo gerado foi testado em um *pipeline* de CSP e LDA, para verificar se a aplicação conseguiria utilizar o arquivo corretamente. No entanto, os resultados obtidos neste teste são irrelevantes, dado que não há padrões a serem classificados nos eletrodos flutuantes.

### 4.3 Interface

A interface gráfica foi desenvolvida para tornar acessível o uso do aplicativo para indivíduos que não são familiarizados com interfaces textuais/linhas de comando. Outra função da interface é permitir a execução visual e sonora de estímulos para a realização da coleta de imagética motora<sup>1</sup>.

**Figura 27 – Tela principal do aplicativo.**



**Fonte: Autoria própria (2024).**

A Figura 27 representa a tela principal do aplicativo. Essa tela possui em sua parte superior um menu de "Perfil de Coleta", onde é possível criar um novo perfil de coleta ou selecionar um perfil já cadastrado para registrar a coleta realizada. Também nessa tela, do lado esquerdo, está a interface de classificação, onde é possível selecionar o arquivo com o conjunto de dados sobre o qual será executado o *pipeline* e selecionar os métodos de extração e de classificação. Na parte inferior dessa interface, há um console, onde é possível visualizar alguns *logs*, como a inserção e remoção de algoritmos ao *pipeline*, os hiperparâmetros adicionados a esses algoritmos, os resultados das classificações e possíveis erros referentes às configurações dos classificadores (captura de exceções *Try - Catch*). Abaixo do console, existem três botões, respectivamente responsáveis por possibilitar a visualização completa do *pipeline*, iniciar

<sup>1</sup> O funcionamento da interface pode ser visualizado através do vídeo a seguir: <[https://youtu.be/SSPnrEm\\_EvM](https://youtu.be/SSPnrEm_EvM)>.

a execução do *pipeline* e visualização de gráficos gerados pelo processo. Atualmente, o único elemento gráfico gerado é a matriz de confusão.

Do lado direito, é possível ver a interface de coleta, que conta com um seletor de porta, onde é possível escolher o canal de comunicação no qual o dispositivo de coleta está conectado e um botão de "*refresh*", para atualizar a lista de portas disponíveis. Também há um seletor de placas para possibilitar ao programa configurar as funções de coleta. Atualmente, apenas a placa *Cyton* está configurada nesse projeto, mas essa função permite a expansão para outros tipos de placas (como por exemplo o módulo de extensão *Daisy OpenBCI*). Ao pressionar o botão "Iniciar Coleta", é criada uma *thread* para o processamento em paralelo da coleta de dados com o resto da interface. A imagem de relógio serve como indicador de início e fim do processo de estímulo mental de imagética motora, enquanto o botão de volume ao lado serve como opção de auxílio/acessibilidade para permitir que sejam emitidos sons para demarcar o começo e final do estímulo.

**Figura 28 – Tela de criação de usuário.**

A interface "Criar usuário" apresenta os seguintes elementos:

- Nome:** Campo de texto único.
- Descrição breve:** Campo de texto multi-linha.
- Resolução:** Campo de seleção com uma seta verde para baixo.
- N° Canais:** Campo de seleção com uma seta cinza para baixo.
- Canais:** Lista suspensa com opções Fp1, Fp2, F3 e F4.
- Parametros de Coleta:**
  - Runs:** Campo de texto.
  - Rest:** Campo de texto.
  - MI:** Campo de texto.
- Pronto:** Botão de confirmação em verde.

**Fonte: Autoria própria (2024).**

A tela representada na figura 28 é onde são cadastrados os novos usuários. Nessa tela, são inseridos dados como nome do perfil e um campo de descrição breve onde podem ser inseridas informações como tipo de tarefa de imagética motora que está sendo realizada, condições do indivíduo e outras anotações pertinentes. Também estão inseridos os dados técnicos da co-

leta, como a resolução utilizada naquele indivíduo (padrão 10-20, padrão 10-05 etc.), número de canais a serem utilizados durante a coleta e a posição dos canais, visto que os sinais de EEG carregam consigo informações espaciais das seções onde os eletrodos estão instalados. Por fim, os parâmetros de coleta como o número de execuções por teste (*Runs*), o tempo mínimo de descanso (*Rest*) e o tempo de execução da tarefa motora (*MI*).

**Figura 29 – Tela de configuração de CSP.**

Parâmetros CSP

Número de Componentes: 4

Regularização para Covariância: -

Transformação Logarítmica: -

Estimativa de Covariância: concat

Resultado de Saída: average power

Normalização de Traço

A normalização do traço é uma etapa do algoritmo CSP original para eliminar variações de magnitude no EEG entre indivíduos. Não é aplicada em trabalhos mais recentes e pode ter um impacto negativo na ordem do padrão.

CANCELAR PRONT

**Fonte: Autoria própria (2024).**

Na tela presente na Figura 29, é possível ver o ambiente de configuração de hiperparâmetros de métodos. Essa janela especificamente apresenta o *design* das janelas modais do aplicativo, como o nome das variáveis em português e o uso de *tooltips* em cada parte do formulário.

## 5 CONCLUSÕES

### 5.1 Discussão geral

Este trabalho foi capaz de atingir sua premissa inicial, desenvolvendo uma interface gráfica capaz de permitir que os dados de EEG sejam coletados, armazenados e utilizados posteriormente para classificação, com *pipelines* de processamento personalizáveis, de forma rápida e sem o conhecimento de linguagens de programação.

### 5.2 Pesquisas e trabalhos futuros

Uma das primeiras atualizações a serem realizadas é permitir a coleta e classificação em tempo real, para que o sistema possa ser utilizado em aplicações práticas, como acionamento de dispositivos externos. A adição de *logs* contendo erros e execuções, de forma a encontrar possíveis falhas que possam ocorrer nos fluxos de processos e resolvê-las depois também é uma possível melhoria a ser implementada.

Durante a execução do *pipeline*, é retornada a acurácia do modelo executado como métrica de validação. Essa pontuação no momento não é um parâmetro, mas pode ser adicionada futuramente, permitindo que outras métricas sejam utilizadas, como a precisão ou a revocação. Também referente às métricas de avaliação, outros gráficos podem ser adicionados, como o *plot* do sinal utilizado, a curva de avaliação do modelo, *headplot* referente ao CSP, dentre outros. Esses gráficos podem ser implementados juntamente do gráfico da matriz de confusão presente no momento, bem como a opção de salvar as imagens e os resultados como relatórios separados de execução. Atualmente, os resultados das execuções dos *pipelines* não ficam salvos. Permitir que a cada execução os resultados sejam salvos no perfil do usuário no qual a classificação foi executada pode facilitar a análise futura dos melhores algoritmos para aquele caso.

Os arquivos gerados pelas coletas são em formato .CSV, que funciona, porém não é o ideal para esse tipo de dado. Outras opções existem, como arquivos .FIF ou .EDF (formatos que estão implementados atualmente, para a leitura dos *datasets* usados durante a etapa de teste). Outra consideração importante a ser realizada é sobre o armazenamento *online* dos arquivos, a fim de permitir que os aplicativos que sejam executados pelo *desktop* possam acessar dados de EEG de forma local ou remota.

Por último, a melhoria de experiência do usuário, como a revisão da disposição da interface, esquema de cores, adição de indicadores de tempo de espera para a conclusão dos métodos, sistema de tradução para outros idiomas e demais elementos de polimento da interface gráfica é um processo de fluxo contínuo e deve ser analisado também durante a execução dos próximos trabalhos.

### 5.3 Considerações finais

Esse trabalho atingiu seu objetivo final ao desenvolver um aplicativo para a classificação de sinais neurológicos de imagética motora, permitindo a coleta de dados de EEG de forma não-invasiva e armazenando-os em arquivos que podem ser utilizados em pesquisas futuras. Foi criada com sucesso uma interface gráfica capaz de executar *pipelines* contendo métodos de extração de características e classificação de dados, bem como selecionar seus hiperparâmetros e verificar os resultados através da acurácia e da matriz de confusão. Embora não tenha sido desenvolvido um sistema de classificação em tempo real, o sistema de coleta de imagética motora funciona corretamente para os propósitos desse projeto.

## REFERÊNCIAS

- AGHAEI, A. S.; MAHANTA, M. S.; PLATANIOTIS, K. N. Separable common spatio-spectral patterns for motor imagery bci systems. **IEEE Transactions on Biomedical Engineering**, v. 63, n. 1, p. 15–29, 2016.
- ANSARI, N. *et al.* Automatic removal of ocular and cardiac artifacts and retention of embedded EEG information via adaptive noise cancellation. *In: 2023 International Conference on Recent Advances in Electrical, Electronics & Digital Healthcare Technologies (REEDCON)*. [S.l.]: IEEE, 2023.
- BEAR, M. F.; CONNORS, B.; PARADISO, M. **Neuroscience**. 4. ed. Philadelphia, PA: Lippincott Williams and Wilkins, 2015.
- BLANKERTZ, B. *et al.* The berlin brain-computer interface: Report from the feedback sessions.
- DIEZ, P. (Ed.). **Smart Wheelchairs and Brain-computer Interfaces**. San Diego, CA: Academic Press, 2018.
- ENGLEHART, K.; HUDGINS, B. A robust, real-time control scheme for multifunction myoelectric control. **IEEE Transactions on Biomedical Engineering**, v. 50, n. 7, p. 848–854, 2003.
- FRØLICH, L.; DOWDING, I. Removal of muscular artifacts in EEG signals: a comparison of linear decomposition methods. **Brain Inform.**, Springer Nature, v. 5, n. 1, p. 13–22, mar. 2018.
- GRAMFORT, A. *et al.* MEG and EEG data analysis with MNE-Python. **Frontiers in Neuroscience**, v. 7, n. 267, p. 1–13, 2013.
- HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. **The Elements of Statistical Learning: Data Mining, Inference, and Prediction**. [S.l.]: Springer New York, 2013. (Springer Series in Statistics). ISBN 9780387216065.
- HAYKIN, S. **Neural Networks: A Comprehensive Foundation**. [S.l.]: Prentice Hall, 1999. (International edition). ISBN 9780139083853.
- HINDARTO, H.; MUNTASA, A.; SUMARNO, S. Fourier transform for feature extraction of electroencephalograph (eeg) signals. **Journal of Physics: Conference Series**, v. 1402, p. 066027, 12 2019.
- HOMAN, R. W.; HERMAN, J.; PURDY, P. Cerebral location of international 10–20 system electrode placement. **Electroencephalogr. Clin. Neurophysiol.**, Elsevier BV, v. 66, n. 4, p. 376–382, abr. 1987.
- IERACITANO, C. *et al.* A novel multi-modal machine learning based approach for automatic classification of eeg recordings in dementia. **Neural Networks**, v. 123, p. 176–190, 2020. ISSN 0893-6080. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0893608019303983>.
- JAMES, G. *et al.* **An Introduction to Statistical Learning: with Applications in R**. [S.l.]: Springer New York, 2013. (Springer Texts in Statistics). ISBN 9781461471387.
- JÚNIOR, P. B. *et al.* Influence of eeg channel reduction on lower limb motor imagery during electrical stimulation in healthy and paraplegic subjects. **Research on Biomedical Engineering**, 2022.



JURCAK, V.; TSUZUKI, D.; DAN, I. 10/20, 10/10, and 10/5 systems revisited: Their validity as relative head-surface-based positioning systems. **NeuroImage**, v. 34, n. 4, p. 1600–1611, 2007. ISSN 1053-8119. Disponível em: <https://www.sciencedirect.com/science/article/pii/S1053811906009724>.

KOLES, Z. J.; LAZAR, M. S.; ZHOU, S. Z. Spatial patterns underlying population differences in the background EEG. **Brain Topogr.**, Springer Nature, v. 2, n. 4, p. 275–284, 1990.

KUBAT, M. **An Introduction to Machine Learning**. [S.l.]: Springer International Publishing, 2015. ISBN 9783319200101.

KUMAR, J. S.; BHUVANESWARI, P. Analysis of electroencephalography (eeg) signals and its categorization—a study. **Procedia Engineering**, v. 38, p. 2525–2536, 2012. ISSN 1877-7058. INTERNATIONAL CONFERENCE ON MODELLING OPTIMIZATION AND COMPUTING. Disponível em: <https://www.sciencedirect.com/science/article/pii/S1877705812022114>.

LAZCANO-HERRERA, A. G.; FUENTES-AGUILAR, R.; ALFARO-PONCE, M. Eeg motor/imagery signal classification comparative using machine learning algorithms. In: **2021 18th International Conference on Electrical Engineering, Computing Science and Automatic Control (CCE)**. [S.l.: s.n.], 2021. p. 1–6.

LIU, A. *et al.* Feature selection for motor imagery eeg classification based on firefly algorithm and learning automata. **Sensors**, v. 17, p. 2576, 11 2017.

LIU, Y.; SOURINA, O. Eeg-based subject-dependent emotion recognition algorithm using fractal dimension. In: **2014 IEEE International Conference on Systems, Man, and Cybernetics (SMC)**. [S.l.: s.n.], 2014. p. 3166–3171.

MASKELIUNAS, R. *et al.* Consumer-grade EEG devices: are they usable for control tasks? **PeerJ**, PeerJ, v. 4, n. e1746, p. e1746, mar. 2016.

MCFARLAND JANIS DALY, C. B. D. J.; PARVAZ, M. A. Therapeutic applications of bci technologies. **Brain-Computer Interfaces**, Taylor Francis, v. 4, n. 1-2, p. 37–52, 2017. Disponível em: <https://doi.org/10.1080/2326263X.2017.1307625>.

MILNE-IVES, M. *et al.* At home eeg monitoring technologies for people with epilepsy and intellectual disabilities: A scoping review. **Seizure: European Journal of Epilepsy**, v. 110, p. 11–20, 2023. ISSN 1059-1311. Disponível em: <https://www.sciencedirect.com/science/article/pii/S1059131123001309>.

MISHRA, A. *et al.* Microsurgical subpial resections for diffuse gliomas-old wine in a new bottle. **Acta Neurochir. (Wien)**, Springer Science and Business Media LLC, v. 162, n. 12, p. 3031–3035, dez. 2020.

MUMTAZ, W.; RASHEED, S.; IRFAN, A. Review of challenges associated with the eeg artifact removal methods. **Biomedical Signal Processing and Control**, v. 68, p. 102741, 2021. ISSN 1746-8094. Disponível em: <https://www.sciencedirect.com/science/article/pii/S1746809421003384>.

NAJARIAN, K.; SPLINTER, R. **Biomedical Signal and Image Processing, Second Edition**. Taylor & Francis, 2012. ISBN 9781439870334. Disponível em: <https://books.google.com.br/books?id=Gi-GOtnHAtAC>.

NALON, J. A. **Introdução ao Processamento Digital de Sinais**. LTC, 2009. ISBN 9788521616467. Disponível em: <https://books.google.com.br/books?id=SeCBPgAACAAJ>.

- OPPENHEIM, A. V.; SCHAFER, R. W. **Processamento em Tempo Discreto de Sinais**. [S.l.: s.n.], 2013.
- PAWAN; DHIMAN, R. Machine learning techniques for electroencephalogram based brain-computer interface: A systematic literature review. **Measurement: Sensors**, v. 28, p. 100823, 2023. ISSN 2665-9174. Disponível em: <https://www.sciencedirect.com/science/article/pii/S2665917423001599>.
- PEDREGOSA, F. *et al.* Scikit-learn: Machine learning in Python. **Journal of Machine Learning Research**, v. 12, p. 2825–2830, 2011.
- PHILIP, B. S.; PRASAD, G.; HEMANTH, D. J. Non-stationarity removal techniques in meg data: A review. **Procedia Computer Science**, v. 215, p. 824–833, 2022. ISSN 1877-0509. 4th International Conference on Innovative Data Communication Technology and Application. Disponível em: <https://www.sciencedirect.com/science/article/pii/S1877050922021561>.
- PRASHANT, P.; JOSHI, A.; GANDHI, V. Brain computer interface: A review. *In*: **2015 5th Nirma University International Conference on Engineering (NUiCONE)**. [S.l.: s.n.], 2015. p. 1–6.
- RUSSELL, S.; NORVIG, P. **Artificial Intelligence: A Modern Approach**. [S.l.]: Pearson, 2021. (Pearson series in artificial intelligence). ISBN 9781292401133.
- RUTKOWSKI, G.; PATAN, K.; LEŚNIAK, P. Comparison of time-frequency feature extraction methods for eeg signals classification. *In*: RUTKOWSKI, L. *et al.* (Ed.). **Artificial Intelligence and Soft Computing**. Berlin, Heidelberg: Springer Berlin Heidelberg, 2013. p. 320–329. ISBN 978-3-642-38610-7.
- SCHALK, G. *et al.* BCI2000: a general-purpose brain-computer interface (BCI) system. **IEEE Trans Biomed Eng**, United States, v. 51, n. 6, p. 1034–1043, jun. 2004.
- SHAD, E. H. T.; MOLINAS, M.; YTTERDAL, T. Impedance and noise of passive and active dry EEG electrodes: A review. **IEEE Sens. J.**, Institute of Electrical and Electronics Engineers (IEEE), v. 20, n. 24, p. 14565–14577, dez. 2020.
- SHAH, A. K.; MITTAL, S. Invasive electroencephalography monitoring: Indications and presurgical planning. **Ann. Indian Acad. Neurol.**, Medknow, v. 17, n. Suppl 1, p. S89–94, mar. 2014.
- SHARMA, R.; KIM, M.; GUPTA, A. Motor imagery classification in brain-machine interface with machine learning algorithms: Classical approach to multi-layer perceptron model. **Biomedical Signal Processing and Control**, v. 71, p. 103101, 2022. ISSN 1746-8094. Disponível em: <https://www.sciencedirect.com/science/article/pii/S1746809421006984>.
- SINGH, A. K.; KRISHNAN, S. Trends in eeg signal feature extraction applications. **Frontiers in Artificial Intelligence**, v. 5, 2023. ISSN 2624-8212. Disponível em: <https://www.frontiersin.org/articles/10.3389/frai.2022.1072801>.
- TANG, X. *et al.* A spatial filter temporal graph convolutional network for decoding motor imagery eeg signals. **Expert Systems with Applications**, v. 238, p. 121915, 2024. ISSN 0957-4174. Disponível em: <https://www.sciencedirect.com/science/article/pii/S095741742302417X>.
- TORTORA, G. J.; DERRICKSON, B. H. **Principles of anatomy and physiology**. Nashville, TN: John Wiley & Sons, 2014.
- URIGÜEN, J. A.; GARCIA-ZAPIRAIN, B. EEG artifact removal-state-of-the-art and guidelines. **J. Neural Eng.**, IOP Publishing, v. 12, n. 3, p. 031001, jun. 2015.

World Health Organization. **Non-communicable diseases Portal**. 2019. Acesso em: 13 de março de 2024. Disponível em: <https://ncdportal.org/CountryProfile/GHE110/BRA>.

World Health Organization. **Spinal cord injury**. 2024. Acesso em: 04 de maio de 2024. Disponível em: <https://www.who.int/news-room/fact-sheets/detail/spinal-cord-injury>.

ZHANG, Y.; JI, X.; ZHANG, Y. Classification of eeg signals based on ar model and approximate entropy. *In*: **2015 International Joint Conference on Neural Networks (IJCNN)**. [S.l.: s.n.], 2015. p. 1–6.

ZHUANG, M. *et al.* State-of-the-art non-invasive brain–computer interface for neural rehabilitation: A review. **Journal of Neurorestoratology**, v. 8, n. 1, p. 12–25, 2020. ISSN 2324-2426. Disponível em: <https://www.sciencedirect.com/science/article/pii/S2324242622000080>.